

AI 1. 인공지능이란 무엇인가

생성형 AI

- 다양한 콘텐츠를 스스로 창작할 수 있는 능력을 지닌 AI
- 주로 딥러닝 기술 기반, 생성 모델로 불리는 신경망 구조 사용
- 트랜스포머 기반의 LLM
- LLM: 대량의 텍스트 데이터를 학습하여 자연어를 이해하고 생성하는 능력을 갖춘 AI 모델

해론의 발명품 (B.C. 3C)

- 자동문: 물을 끓인 증기로 문을 열리게 하는 방식

피에르 자케 드로의 자동기계 (A.D. 18C)

- 펜을 들고 글을 쓰는 자동 인형
- 그림을 그리는 자동 인형

배비지의 해석 기관 (A.D. 19C)

- 컴퓨터의 기본 개념을 모두 갖춘 장치
- (해석기관 이전) 차분 기관: 특정 수학 문제만을 해결. But 해석기관은 범용 컴퓨터
- 복잡한 수학적 연산 가능. 입력장치, 처리장치, 메모리, 출력장치로 구성(컴퓨터의 기본 요소)

에이다 러브레이스

- 최초의 프로그래머, 해석기관에 대한 설명과 주석 작성
- 주석에는 컴퓨터 프로그램 포함됨 (최초의 알고리즘)

인공지능

- 기계가 인간의 지능을 모방하여 복잡한 문제 해결, 상황에 맞는 의사결정을 내릴 수 있게 하는 기술
- 인간과 유사한 방식으로 데이터를 분석, 처리하여 결과 도출
- 인간 지능 사고의 특징: 학습(Learning), 추론(Reasoning), 자각(Perception)
- 중요한 네 가지 측면
 - 인간처럼 사고, 합리적으로 사고, 인간처럼 행동, 합리적으로 행동
 - 「인공지능」 용어는 1956년 다트머스 회의에서 제안

딥러닝

- 인공지능 ≧ 머신러닝 ≧ 딥러닝
- 머신러닝: 컴퓨터가 학습
- 딥러닝: 인공신경망 사용하여 학습

튜링 테스트

- “기계와 사람을 구분할 수 없다면 인공지능이 구현된 것”
- 컴퓨터와 질문자가 5분동안 대화하여 질문자가 컴퓨터입을 인식하지 못하면 인공지능이 구현된 것

기호주의 AI

- 기호와 규칙으로 인공지능을 구현하려는 방식
- 「조합폭발」 - 조합 가능한 경우의 수가 천문학적으로 증가

연결주의 AI

- 인간 두뇌는 뉴런의 전기적 네트워크로 고려
- 인공신경망으로 발전
- XOR 문제 등에서 한계

AI 겨울

- 첫 번째: 낙관주의의 붕괴
- 두 번째: 기대만큼 혁신적이거나 실용적이지 않음. 컴퓨팅 자원의 한계
- 머신러닝(혹은 딥러닝)의 부흥, 데이터의 폭발적인 증가(빅데이터)로 부활

전문가 시스템

- 전문가로부터 습득한 IF-THEN 식의 규칙들로 문제를 해결하는 프로그램
- 조금만 예외적이 상황에 대응 못함(노이즈에 취약함)

불쾌한 골짜기

- 인공지능이 인간처럼 보이거나 행동할 때, 너무 현실적이면 사람들에게 불쾌감이나 거부감을 줄 수 있음

AI 2. 생성형 AI란 무엇인가

GAN

- 생성자와 판별자 알고리즘이 경쟁하면서 점점 현실적인 데이터를 생성하는 모델
- 생성자: 가짜 데이터를 생성하는 방법을 학습. 생성된 데이터는 판별자의 학습 데이터가 됨
- 판별자: 생성자의 가짜 데이터를 진짜 데이터와 구분하는 방법 학습.

오토 인코더

- 데이터의 효율적인 표현을 학습. 데이터 압축과 복원을 목적으로 사용됨.
- 입력 데이터를 압축하여 잠재 공간으로 표현, 다시 원래 데이터로 복원
- 인코더: 입력 데이터를 압축해 저차원 공간으로 변환
- 디코더: 압축한 잠재 공간을 바탕으로 다시 원래 형태로 복원

빅데이터 1. 빅데이터

빅데이터

- 기존 시스템으로 처리 가능한 범위를 넘어서는 방대한 데이터
- 3V: Volume, Velocity, Variety
 - 기존 기술로는 관리가 쉽지 않은 데이터 양
 - 텍스트 데이터, 위치 정보, 센서 데이터, 동영상 등 다양한 비구조화 데이터
 - 실시간각 발생
- 정형, 반정형, 비정형
 - 정형: 고정된 필드에 저장된 데이터
 - 반정형: 메타데이터, 스키마 등으로 일정한 정형성 가짐
 - 비정형: 고정된 필드 없음
- 빅데이터 분석기법: 다양한 빅데이터 종류들을 분석하기 위한 기법
 - 정형 데이터: 전통적 방법
 - 비정형 데이터: 텍스트 마이닝, 오피니언 마이닝, 소셜 네트워크 분석 등
 - 데이터 시각화: 정보 시각화, 과학적 시각화, 인포그래픽스
- 빅데이터 분석 인프라 기술: 대용량 자료처리와 분석을 위한

정형데이터 분석

- 기술통계 분석: 데이터가 가진 일반적인 특성 분석
- 추론통계 분석: 집단 간 비교, 차이 분석 및 상호 관련성에 대해서 분석
- 데이터마이닝 분석: 대규모 데이터에 숨어있는 패턴 발견, 규칙 도출

기술통계 분석

- 자료의 특성을 쉽게 파악할 수 있도록 묘사
- 수집한 자료의 주요한 특성 분석
- 평균값, 중앙값, 최빈수 값, 최댓값, 최솟값, 범위, 분산, 표준편차, 변동계수, 왜도, 첨도 등
- 빅데이터 분석에는 빈도분석, 기술분석, 교차분석, 다차원 척도분석 등 활용

추론통계 분석

- 수집한 데이터에서 표본 추출, 특정 파악 후 모집단의 특성으로 일반화
- 표본을 기초로 미래나 전체를 예측
- 평균차이분석, 비율차이분석, 분산분석, 상관관계분석, 회귀분석 등

데이터마이닝

- 대용량의 데이터로부터 기존에 알려지지 않은 정보를 추출하는 지식발견과정
- 다면적, 복합적 성격을 지닌 대용량 데이터로부터 유용한 정보 산출하는 지식 발견 방법
- 데이터에서 필요한 정보를 탐색, 정보의 패턴 분석
- 분류분석, 예측분석, 군집분석, 연관분석 등

비정형데이터분석

- 텍스트 마이닝: 자연어처리 기술을 이용, 유용 정보 추출
 - 주제어 분석, 단어 간 연관성 분석, 토픽 모델링, 오피니언 마이닝 등
- 오피니언 마이닝: 글쓴이의 의견, 감정, 평가, 태도 판별
 - 텍스트로부터 긍정, 부정, 중립 등의 선호도 판별
- 소셜 네트워크 분석: 구체적인 모습을 파악하기 어려운 연결 구조 파악에 사용
 - 그래프 이론에 근거하여 네트워크 연결구조, 영향력 등 측정
 - 영향력 있는 사용자, 「인플루언서」로 명칭

데이터시각화

- 데이터 분석 결과를 직관적으로 이해할 수 있도록 일목요연하게 그래프로 표현
- 정보 시각화, 과학적 시각화, 인포그래픽스
 - 정보 시각화: 대규모 데이터를 도표, 색상, 그래프 등을 활용해 요약적으로 표현
 - 복잡한 데이터를 쉽게 탐색하도록 3차원 그래픽 기술 등을 활용(실험 결과, 시뮬레이션 데이터 등에 사용)
 - 자신의 데이터를 이해하고 통찰력을 얻기 위해 그래픽 표현하는 데 목적

인포그래픽

- 인포메이션 + 그래픽
- 대량의 복잡한 수치, 글 ⇒ 표, 그래프, 지도, 다이어그램, 로고, 일러스트 등으로 표현
- 방대한 정보를 쉽고 빠르게 이해하도록 함

빅데이터 분석 인프라 기술

- 대규모 데이터 처리를 위한 하드웨어/소프트웨어 기술 포함하는 개념
- 데이터 저장, 처리, 분석, 시각화로 구분
- 데이터 저장: 분산파일시스템(DFS) - HDFS, Amazon S3, Google Cloud Storage, Delta Lake
 - 데이터베이스 시스템: 조직에 필요한 정보를 얻기 위해서 논리적으로 연관된 데이터를 모아 구조적으로 통합 저장하는 시스템
 - RDBMS: 데이터를 테이블로 관리
 - NoSQL: RDBMS의 한계 극복하기 위한 DB(MongoDB, Cassandra, Hbase 등)
 - NewSQL: RDBMS + NoSQL + ACID 트랜잭션 특성, NoSQL의 수행 확장성 (Google Spanner, CockroachDB, TiDB 등)
- 데이터 웨어하우스: 여러 출처에서 수집된 데이터를 분석/의사결정에 사용 하도록 통합 저장

- 중앙 집중형 데이터 저장소...정영진이나 분석가의 의사결정 지원, 과거 데이터 기반 추세분석(Amazon Redshift, Google BigQuery 등)
- 데이터 처리: 대량의 데이터 효율적으로 처리하기 위한 기술
 - 배치 처리: 개별 데이터의 실시간 처리가 아니라, 한꺼번에 모아서 일괄적으로 처리
 - (업무 자동화, 대규모 데이터 처리, 정기 보고서 생성 등)
 - (Hadoop MapReduce, Apache Spark, Flink 등)
 - 스트리밍 처리: 실시간으로 데이터를 추출, 처리, 전달(Apache Kafka, Apache Flink, Apache Storm, Google Dataflow 등)
- 데이터 분석: 데이터를 수집하고 처리한 후, 다양한 기법으로 분석, 의미있는 정보를 도출하는 작업
 - 머신러닝/딥러닝(TF, Torch, MLflow, KubeFlow 등)
 - 빅데이터 분석 프레임워크(Apache Hive, Presto, Apache Drill 등)
- 데이터 시각화: 데이터를 직관적으로 이해할 수 있도록 지도나 그래프로 시각화하는 기술
 - BI: 기업이 데이터를 수집하고 분석, 의사결정을 내리는 데 사용하는 SW. 분석된 결과를 시각적으로 보여줌 (Tableau, PowerBI, Looker 등)
 - 오픈소스 시각화 라이브러리: Matplotlib, D3.js, chart.js 등

빅데이터 2. R 기초

R 개요

- S언어(통계 프로그래밍 언어) 기반
- 통계/그래픽을 위한 프로그래밍 언어
- 통계 소프트웨어 개발과 자료 분석에 광범위하게 사용
- 패키지 개발 용어(R에 기반 둔 응용 패키지 생산/배포 지원하는 CRAN)
- CRAN에는 수만개 이상의 패키지들 사용 가능. 실무 분야에서도 정형/비정형 데이터의 시각화 등 빅데이터 분석 도구들로 활용됨
- 기본적인 통계 분석 기법, 데이터 마이닝, 최신 텍스트마이닝 기법까지 구현

R의 특징

- 오픈소스 기반 무료 소프트웨어
- 통합적인 빅데이터 분석 플랫폼 제공
- 대용량 데이터 분산처리 지원
- 웹 프로그래밍 언어와 연계
- 다양한 운영체제 지원
- 뛰어난 시각화 기능
- 작업의 재현성

R 패키지

- 기본 패키지는 별도의 로딩 과정 없음. 추천 패키지는 로딩 과정을 거쳐야 함
- library(package)

패키지명	주요함수	내용	패키지명	주요함수	내용
psych	describe	기술분석	descr	freq	빈도분석
gmodels	CrossTable	교차분석	MASS	isoMDS	다차원 척도분석
Hmisc	rcorr	상관분석	fBasics	skewnewss	왜도분석
fBasics	kurtosis	첨도분석	QuantPsc	lm.beta	회귀분석 표준화계수
prettyR	Mode	최빈값	e1017	naiveBayes	나이브 베이즈 분류 분석
e1017	svm	서포트 벡터 머신			

R의 기능

- 수치계산 - 산술연산자, 함수를 사용하여 수치 계산 수행
- 데이터 유형: (특수형) 결측치 NA, 비숫자 NaN, 무한대 INF (자료구조) 벡터, 행렬, 배열, 데이터프레임, 리스트, 요인(factor)

빅데이터 3. R 프로그래밍과 그래픽

프로그래밍

- 목적하는 결과를 생성하기 위해 컴퓨터에게 명령을 내리는 것
- 다수의 명령어들을 연결하는 방식으로 수행
- 산술 연산, 논리 연산을 위한 다양한 연산자와 조건에 따라 다른 계산을 수행하는 조건 명령어
- 프로그래밍의 효율성을 위해 특정 부분 명령을 반복 수행하게 하는 반복 명령어로 구성

그래프

- R 기본 그래프 함수들은 고수준 그래프와 저수준 그래프 함수로 구분
 - 고수준 그래프 함수: 완성된 하나의 그래프를 그리는 데 사용
 - 저수준 그래프 함수: 각 그래픽 요소를 그림; 범례/선 등 추가적인 장식에 일반적으로 사용
- 그래프 저장 명령으로 이미지 파일, pdf파일 등으로 저장 가능

빅데이터 4. R 자료관리 및 수집

데이터 생성

- edit 함수 이용: 엑셀처럼 데이터 편집기 창 생성
- 외부에서 데이터 불러오기(엑셀 readxl, csv 파일 등)

데이터 탐색

- 새롭게 생성된 데이터 셋을 활용할 때, 데이터 객체의 현황, 특성에 대해서 파악하여야 한다.
- head/tail(기본값: 6개), dim, Names, class

데이터의 분할 및 추출

- 데이터프레임에서 자료분할: 새 데이터프레임을 생성
- 전체 데이터에서 일부 변수의 값만 추출하여 데이터프레임 생성subset

데이터의 병합

- 데이터프레임을 수직적cbind, 수평적rbind으로 결합

데이터의 정렬

- 특정 항목을 기준으로 자료를 오름/내림차순으로 정렬
- order - data[order(data\$colname, -data\$colname),]
- apply - apply(data, 1 or 2, fn)

빅데이터 자료 수집

- 빅데이터 분석 수행을 위해서 데이터를 수집하는 방법: 내부 데이터 이용/외부로부터 데이터 수집
 - 내부 데이터 이용: 데이터 웨어하우스 구축, 분석에 필요한 자료 추출
 - 외부 데이터 수집: 빅데이터 제공 기관의 파일 데이터셋, 웹 스크래핑, 오픈 API
 - 공공 데이터포털 등에서 데이터 제공(csv, 엑셀, 텍스트 등)
 - 공공 데이터 포털: 교육, 국토관리, 공공행정, ㅓ정금융, 산업고용 등 다양한 영역...국민이 쉽고 편리하게 공공데이터 이용할 수 있도록

웹 스크래핑 자료 수집

- 웹문서로부터 유용한 정보 추출, HTML로 구성된 웹사이트에서 데이터 추출
- 비구조화된 웹 문서 자료를 정형화하여 DB/엑셀에 저장 분석할 수 있음
- 온라인 마켓의 상품 정보, 뉴스 기사, 블로그/카페 게시물, 영화 후기 등 수집
- rvest, stringr 패키지 사용
- 스크래핑 절차: 대상 URL로부터 웹 문서를 가져와 특정 태그 아래의 데이터 추출
 1. 웹 스크래핑 대상 URL 할당
 2. 웹 문서 가져오기
 3. 특정 태그의 데이터 추출
 4. 데이터 정제
 5. 데이터 프레임 생성

오픈 API 사용 자료수집

- 오픈 API: 웹 2.0의 대표적인 기술, 자신이 보유한 정보/서비스 등을 공개하여 타 시스템에서 사 용할 수 있도록 제공
- 공공 데이터 접근에는 REST API 사용됨
- REST API: HTTP의 기본 메서드 GET/POST/PUT/DELETE를 사용해 자료 요청; 요청 자료는 XML, JSON, HTML등으로 응답
- XML 패키지 사용
- 자료수집 수행절차
 1. 오픈 API 제공 웹사이트에 접속 및 로그인
 2. 오픈 API 자료 검색
 3. 활용 신청 및 개발 계정 API 키 신청
 4. 승인 받은 개발 계정 API 키 확인
 5. 오픈 API 접속을 위한 웹 URL, 요청 변수 확인
 6. R에서 오픈 API를 이용한 자료 요청
 7. 데이터프레임 생성

빅데이터 5. 데이터 기술통계

기술통계

- 수집한 자료에 대한 정리, 표현, 요약, 해석 등을 통해 자료의 특성을 규명
- 빈도분석, 기술분석, 교차분석, 다차원 척도법 등

통계자료의 종류

- 범주형 자료
 - 명목척도: 남녀 구별, 결혼 여부 등
 - 서열척도: 선호 순위, 성적 순위 등
 - 양적 비교 불가
- 연속형 자료
 - 등간척도: 온도, 물가 지수, 만족도 등
 - 양적 비교 가능; 절대값 확인 불가
 - 비율척도: 중량, 매출액, 소득 등
 - 산술 연산 가능

빈도분석

- 자료의 특정 변수에 대해 차지하는 측정값들의 수량(빈도와 비율 산출 분석)
 - ⇒ 전체적인 분포 특성을 파악
- 범주형 변수에 대해 빈도표 작성 후 적절한 막대그래프, 파이차트 등의 그래프 그림
- 기술분석
 - 자료의 특성을 쉽게 파악할 수 있도록 묘사하는 것을 목적, 자료의 주요한 특성 파악
 - 자료의 중심경향성 파악(평균값, 중앙값, 최빈수)
 - 자료의 변동성 측정(최대값, 최소값, 분산, 범위, 왜도, 첨도 등)

교차분석

- 범주형 자료(두 개 이상의 변수)에 대해 교차되는 빈도를 표로 나타냄
- 빈도분석: 한 개 변수에 대한 빈도 측정
- 교차분석: 두 개 변수 교차한 자료에 대한 빈도 분석
- 독립성 여부 검증: 카이제곱

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- 실험결과: 실제빈도, 기대빈도, 열기준비율, 행기준비율, 전체비율이 포함된 교차표 산출됨; 카이 제곱 검정거로가: 하단에 나타남

다차원척도법

- 자료들 사이의 유사성/비유사성 측정 ... 2차원/3차원 공간상에 점으로 표현
- 자료들 간의 근접성을 시각화하여 데이터 속 잠재된 패턴, 구조 찾아냄
- 참고: 유클리드 거리

$$\sqrt{\sum_{i=1} (X_{1i} - X_{2j})^2}$$

그룹 분석

- 자료를 집단별로 나누어 그룹 함수를 적용
- 빈도분석: 그룹별 빈도만 산출
- 그룹분석: 빈도 + 그룹별 특정 값에 대한 합계, 평균, 표준편차, 중앙값 등 정보 확인 가능
- dplyr 패키지

탐색적 데이터 분석

- 기존 통계학이 정보의 추출에서 가설 검증 등에 치우쳐있음...자료가 갖는 본연의 의미를 찾는 데 어려움
- 주어진 자료만 가지고도 충분한 자료를 찾을 수 있도록 제공된 자료 분석 기법
- 박스 플롯, 산포도, 줄기 잎 도표, Q-Q 도표 등
 - 박스 플롯: 자료 집합의 범위와 중앙값 빠르게 확인
 - 산포도: 두 변수 간의 영향력 보여주기 위해 가로 축/세로축에 자료를 점으로 그림
 - 줄기 잎 도표: 줄기에 해당되는 단위 설정 → 하위 단위 자료, 잎의 크기 순서로 배열
 - Q-Q 도표: 데이터가 특정한 분포를 따르는지 시각적 검토(사분위수 기리 좌표 평면에 표시)

빅데이터 6. 데이터 추론통계

추론통계

- 수집한 데이터에서 표본 추출하여 특성 파악 ... 모집단의 특성으로 일반화 가능한지 여부 판단
 - ⇒ 모수를 추정
- 모집단: 정보를 얻고자 하는 대상이 되는 집단
- 모수parameter: 모집단의 특성을 나타내는 정도
- 표본: 모집단으로부터 추출된 적당한 크기의 관측값들의 모임

- 평균차이 분석, 비율차이 분석, 분산분석, 상관분석, 회귀분석 등

- “모집단으로부터 추출된 표본으로부터 계산되는 통계량을 이용하여 모집단의 특성인 모수를 추정”

빅데이터 분석에서, 추론통계의 의의

- (빅데이터) 데이터가 모집단 수에 근접할 경우, 기술통계만으로도 모수 추정 가능
- (빅데이터) 적은 수의 표본에 의존한 모수추정보다 예측된 모수에 대한 정확도가 높아지는 장점

평균차이분석

- t-검정 ... 두 집단 간 평균의 차이가 통계적으로 유의한지 파악
 - 특정 쇼핑물에 대한 이용 만족도, 남녀 차이 있는가?
- 종류
 - 독립 표본 평균 차이 분석: 표본의 수가 다른 두 집단에 대한 비교
 - 대응 표본 평균 차이 분석: 표본의 수가 같은 두 집단, 한 집단에 대한 특정 사건 전후 차이 비교

비율차이분석

- 두 집단에 대해 두 집단 간 비율의 차이가 통계적으로 유의한지 파악
 - 쿠폰 선호 여부, 남녀 차이 있는가?
- 일반적으로 T/F의 이항형 자료 차이 검정에 사용

분산분석

- 두 표본 이상(세 집단 이상)의 평균치에 대한 차이 검정
 - 통계학을 수강하는 학생들의 점수, 학년별로 유의한 차이 있는가?
- “3개 이상 집단에 대해 평균 차이 비교할 때 사용”
- 집단 내 분산, 집단 간 평균 차이 ⇒ 집단간 분산의 비교 ⇒ 형성된 F-분포를 이용해 가설검정
- 종류
 - 일원배치 분산분석 $X \Rightarrow Y$
 - 이원배치 분산분석 $X, A \Rightarrow Y$
 - *반복측정 분산분석 ... 동일한 개체들, 시간에 따라 어떻게 변하는가

상관관계분석

- 두 변수 간의 관련성 분석
 - 쇼핑액과 지출액 사이에 관련성이 있는가?
- 상관계수: 두 변수 간 관련성 정도 표현하는 값

$$\text{상관계수 } r = \frac{X \text{와 } Y \text{가 함께 변하는 정도}}{X \text{와 } Y \text{가 각각 변하는 정도}}$$

회귀분석

- 변수들 사이의 인과관계를 규명
 - ... 다른 변수에 영향을 주는 변수 = 독립변수,
 - ... 영향을 받는 변수 = 종속변수
 - 이들 사이의 선형 방정식(=회귀식) 찾아내기
- 등간척도, 비율척도 등의 연속형 변수들로 측정

통계적 추정과 가설검정

- 정규분포
 - 연속적이고 좌우대칭인 종 모양의 확률분포 ... 실생활에서 관측하는 대부분 자료들의 분포
- t-분포
 - 모집단이 정규분포더라도 분산이 알려져있지 않고 표본 수가 적은 경우, 모평균에 대한 추정, 가설 검정에 사용
- F-분포
 - 동일한 분산을 가지는 정규분포 모집단으로 추출된 표본, 표본 분산들간의 비율이 이루는 분포
 - 분산분석, 회귀분석에서의 회귀식의 유의성 검증
- χ^2 분포
 - 정규분포를 이루고 있는 모집단, 각 표본의 표준화된 분산의 합이 이루는 분포
 - 교차분석에서 관찰 빈도와 기대 빈도 간의 차이 검정, 비율 분석 수행...에 사용

추론통계에서 가설검정 절차

1. 가설 설정: 귀무가설과 대립가설로 구분해 설정
2. 귀무가설 하 검정에 필요한 적절한 검정통계량 계산
3. 귀무가설의 채택 여부 판단 기준(=유의수준) 설정
4. 표본으로부터 계산된 검정통계량 값 기준, 유의확률(P-value) 계산
5. 계산된 유의확률, 사전에 설정한 유의수준 비교 ... 귀무가설 기각 여부 결정
6. 검정결과, 요약 기술