

AI 1. 인공지능이란 무엇인가

생성형 AI

- 다양한 콘텐츠를 스스로 창작할 수 있는 능력을 지닌 AI
- 주로 딥러닝 기술 기반, 생성 모델로 불리는 신경망 구조 사용
- 트랜스포머 기반의 LLM
- LLM: 대량의 텍스트 데이터를 학습하여 자연어를 이해하고 생성하는 능력을 갖춘 AI 모델

인공지능 역사

- 해론(B.C. 3C): 자동문 - 증기로 문을 자동으로 열게 함
- 피에르 자케 드로(A.D. 18C): 글 쓰는 인형, 그림 그리는 인형
- 배비지(A.D. 19C): 해석 기관 - 컴퓨터 기본 요소 모두 갖춘(입력/처리/메모리/출력)
- 에이다 러브레이스: 최초의 프로그래머, 최초의 알고리즘 기술
- 1956년 님스릭 회의: 「인공지능」 용어 제안

인공지능 정의

- 기계가 인간의 지능을 모방하여 복잡한 문제 해결, 상황에 맞는 의사결정을 내릴 수 있게 하는 기술
- 인간 지능의 특징: 학습(Learning), 추론(Reasoning), 자각(Perception)
- 중요한 네 가지 측면: 인간처럼 사고, 합리적으로 사고, 인간처럼 행동, 합리적으로 행동

AI vs ML vs DL

- AI(인공지능) $\supset$ ML(머신러닝) $\supset$ DL(딥러닝)
- ML: 컴퓨터가 데이터에서 자동으로 학습
- DL: 인공지능망 사용하여 학습

튜링 테스트

- “기계와 사람을 구분할 수 없다면 인공지능이 구현된 것”
- 컴퓨터와 질문자 5분 대화 → 질문자가 컴퓨터 인식 못하면 AI 구현된 것

AI 패러다임 전환

- 기호주의 AI: 기호와 규칙으로 구현 → 「조합폭발」로 한계
- 연결주의 AI: 인공지능망 기반 → XOR 문제 등에서 한계
- AI 겨울: 기대와 현실의 괴리, 컴퓨팅 자원의 한계 → 빅데이터 부흥으로 회생
- 전문가 시스템: IF-THEN 규칙 기반 → 노이즈에 취약
- 불쾌한 골짜기: AI가 너무 현실적이면 거부감/불쾌감 유발

AI 2. 생성형 AI란 무엇인가

생성형 AI 기술

- GAN: 생성자 vs 판별자 경쟁 → 현실적 데이터 생성
 - 생성자: 가짜 데이터 생성 학습
 - 판별자: 진짜/가짜 구분 학습
- 오토 인코더: 데이터 압축/복원
 - 인코더: 입력 → 저차원 공간 변환
 - 디코더: 압축 데이터 → 원래 형태 복원
- Diffusion 모델: 노이즈 → 점진적 복원 → 이미지·비디오 생성 강점

Transformer & Self-Attention

- 2017년 Google 발표 → 순환·컨볼루션 대체
- Self-Attention: 문맥 전체를 한 번에 파악 → 대규모 학습 효율성 ↑
- 현재 대부분 LLM의 기본 아키텍처

생성형 AI 역사

- 1986년: 역전파 재발견 (Hinton 등)
- 1990 2000년: 다층 퍼셉트론 → 심층 신경망
- 2014년: GAN (생성자·판별자 경쟁)
- 2017년: Transformer 기반 혁신
- 2020 2022년: LLM·ChatGPT·Gemini 상용화
- 2024 2026년: 멀티모달 모델 (텍스트·이미지·음성·비디오)

주요 모델 정리

기술	특징	응용
Transformer	Self-Attention, 병렬 학습	BERT, GPT, Gemini
LLM	수백억 수천억 파라미터	ChatGPT, Gemini Pro
GAN	생성자·판별자 경쟁	이미지·비디오 생성
Diffusion	노이즈→점진적 복원	Stable Diffusion, DALL-E
멀티모달	텍스트·이미지·음성·영상	GPT-4V, Dream Machine

시장 규모 & 전망

- 2020년: 3.5억 USD → 2030년: 150억 USD (약 40배 성장)
- 경제 효과: 2030년 글로벌 GDP 7 10조 USD 증가, 생산성 최대 10% 향상
- 주요 적용: 예술·디자인, 마케팅·콘텐츠, 의료·진단, 금융·예측, 교육·맞춤형 학습

마케팅 활용 사례

- 소셜 미디어 포스트 자동 생성 (텍스트 플랫폼 → 여러 카피 자동 작성)
- 제품 이미지/영상 제작 (프로토타입 비주얼, 프로모션 영상)
- 고객 행동·수요 예측 (리뷰 분석 → 맞춤형 추천 문구)

빅데이터 1. 빅데이터

빅데이터 정의

- 기존 시스템으로 처리 가능한 범위를 넘어서는 방대한 데이터
- 데이터 규모 진화: TB → PB → EB → ZB 단위

3V 특징

- Volume: 기존 관리 단위 초과 방대한 규모
- Velocity: 실시간 발생 데이터의 급속한 흐름
- Variety: 정형·반정형·비정형 데이터 혼재
 - 정형: 고정 필드에 저장된 데이터
 - 반정형: 메타데이터, 스키마로 일정한 정형성 가짐
 - 비정형: 고정 필드 없음 (문서, 사진, 동영상 등)

정형데이터 분석

- 기술통계: 데이터의 일반적 특성 분석
- 추론통계: 집단 간 비교·차이 분석, 상호 관련성 분석
- 데이터마이닝: 대규모 데이터에서 패턴 발견, 규칙 도출

데이터마이닝

- 대용량 데이터로부터 기존에 알려지지 않은 정보 추출하는 지식발견과정
- 분류분석(Classification): 데이터를 사전 정의된 범주로 분류 → 베이즈, 의사결정트리, SVM 등
- 예측분석(Prediction): 과거 데이터 바탕으로 미래값 예측 → 회귀분석, 시계열분석
- 군집분석(Clustering): 유사한 개체들을 자동으로 그룹화 → K-means, 계층적 군집화
- 연관분석(Association): 변수 간 관계 규칙 발견 → Apriori, 장바구니 분석

비정형데이터 분석

- 텍스트 마이닝: 자연어처리 기술로 유용 정보 추출
 - 주제어 분석, 단어 간 연관성, 토픽 모델링, 오피니언 마이닝
- 오피니언 마이닝: 글쓴이의 의견·감정·태도 판별
 - 텍스트에서 긍정/부정/중립 선호도 판별
- 소셜 네트워크 분석: 연결 구조 파악, 영향력 측정
 - 그래프 이론 기반, 영향력 있는 사용자(인플루언서) 식별
 - 네트워크 구조, 중심성(Centrality), 커뮤니티 탐지

데이터시각화

- 분석 결과를 직관적으로 이해할 수 있도록 표현
- 정보 시각화: 도표·색상·그래프로 요약적 표현
- 과학적 시각화: 3차원 그래픽 기술 활용 (실험결과, 시뮬레이션)
- 인포그래픽: 복잡한 정보 → 표·그래프·지도·다이어그램으로 쉽고 빠르게 이해

빅데이터 분석 인프라 기술 데이터 저장

- 분산파일시스템(DFS): HDFS, Amazon S3, Google Cloud Storage, Delta Lake
- RDBMS: 테이블 기반 관계형 DB
- NoSQL: MongoDB, Cassandra, HBase (RDBMS의 한계 극복)
- NewSQL: ACID 트랜잭션 + NoSQL 수평 확장성 (Google Spanner, CockroachDB)
- 데이터 웨어하우스: 중앙 집중형 저장소 (의사결정 지원, 추세분석)

데이터 처리

- 배치 처리: 대량 데이터 일괄 처리 (Hadoop MapReduce, Apache Spark)
- 스트리밍 처리: 실시간 데이터 처리 (Apache Kafka, Flink, Storm, Google Dataflow)

데이터 분석 & 시각화

- 분석: 머신러닝/딥러닝 (TensorFlow, Torch), 빅데이터 프레임워크 (Hive, Presto, Drill)
- 시각화: BI 도구 (Tableau, PowerBI, Looker), 오픈소스 라이브러리 (Matplotlib, D3.js, Chart.js)

빅데이터 2. R 기초

R 개요 & 특징

- S언어(통계 프로그래밍 언어) 기반, 통계/그래픽 프로그래밍 언어
- 오픈소스 기반 무료 소프트웨어
- CRAN: 수만개 이상의 패키지 유통 (R에 기반 한 응용 패키지 개발 용이)
- 특징: 통합적 빅데이터 분석, 대용량 분산처리, 웹 언어 연계, 범용 OS 지원, 뛰어난 시각화, 작업 재현성

R의 기능

- 수치계산: 산술연산자, 함수 사용
- 데이터 유형
 - 특수형: NA(결측치), NaN(비숫자), INF(무한대)
 - 자료구조: 벡터, 행렬, 배열, 데이터프레임, 리스트, 요인(factor)

R 패키지

패키지	주요함수	내용
psych	describe	기술분석
descr	freq	빈도분석
gmodels	CrossTable	교차분석
MASS	isoMDS	다차원 척도분석
Hmisc	rcorr	상관분석
fBasics	skewness, kurtosis	왜도·첨도
QuantPsc	lm.beta	회귀 표준화계수
e1071	naiveBayes, svm	분류분석
rvest	read_html	웹 스크래핑
readxl	read_excel	엑셀 불러오기
dplyr	group_by, summarise	데이터 조작

빅데이터 3. R 프로그래밍과 그래프

프로그래밍 기본

- 산술 연산, 논리 연산을 위한 다양한 연산자
- 조건에 따라 다른 계산을 수행하는 조건 명령어
- 특정 부분을 반복 수행하는 반복 명령어로 구성

조건문 & 반복문

- if (조건) { 실행 } else { 실행 }
- for (i in 범위) { 실행 } - 정해진 횟수만큼 반복
- while (조건) { 실행 } - 조건이 참인 동안 반복
- apply(data, 1 or 2, fn) - 1(행), 2(열)에 함수 적용

그래프 함수

- 고수준 그래프: 완성된 하나의 그래프를 그림
 - plot(): 2차원 점/선 그래프
 - barplot(): 막대그래프
 - hist(): 히스토그램
 - pie(): 파이 차트
 - boxplot(): 박스 플롯
 - pairs(): 산점도 행렬
- 저수준 그래프: 이미 그려진 그래프 위에 장식 추가
 - title(): 제목 추가
 - lines(), points(), legend(), axis() 등

plot() 함수 주요 인수

- x, y: 축 데이터
- main, sub: 제목·부제목
- xlab, ylab: 축 이름
- type: 그래프 형태 ("p"점, "l"선, "b"점+선, "o"점위의선, "h"수직선, "n"축만)
- col: 색상
- pch: 점 모양 (1 25)
- lty: 선 종류 (1:실선, 2:파선, 3:점선)

화면 제어 & 중복 그래프

- par(new=T): 고수준 함수 실행 시에도 화면을 지우지 않고 겹쳐 그리기

```
barplot(data)
par(new=T)
plot(data, type="o", col="red")
• 그래프를 파일로 저장: pdf(), png() 등
```

빅데이터 4. R 자료관리 및 수집

데이터 생성 & 불러오기

- edit(): 엑셀처럼 데이터 편집기 창 생성
- read.csv(): CSV 파일 불러오기 (옵션: header=T, fileEncoding="EUC-KR")
- readxl::read_excel(): 엑셀 파일 불러오기
- setwd(): 작업 디렉터리 설정

데이터 탐색

- head()/tail(): 앞/뒷부분 6개 행 확인
- dim(): 차원(행, 열) 확인
- str(): 데이터 구조 상세 확인
- summary(): 요약 통계량 확인
- names()/colnames(): 열 이름 확인

데이터 관리

- 분할/추출: subset() - 일부 변수 추출
- 병합: cbind()(수직), rbind()(수평)
- 정렬: order() - data[order(data\$colname),]
- 그룹 함수: dplyr::group_by(), summarise() - 집단별 분석

데이터 수집

- 내부: 데이터 웨어하우스 구축 및 추출
- 외부: 파일 데이터셋, 웹 스크래핑, 오픈 API
 - 공공데이터포털 등에서 CSV·Excel·텍스트 제공

웹 스크래핑

- HTML 기반 웹사이트에서 비구조화된 데이터 추출 → 정형화
- 패키지: rvest, stringr
- 절차: URL 할당 → 웹 문서 가져오기 → 태그별 데이터 추출 → 정제 → 데이터프레임 생성

오픈 API 수집

- REST API: HTTP 메서드(GET/POST/PUT/DELETE) 사용 → XML/JSON/HTML 응답
- 패키지: XML
- 절차: API 웹사이트 접속 → 자료 검색 → 활용 신청 → API 키 획득 → 승인 → 요청 변수 확인 → R에서 데이터 요청 → 데이터프레임 생성

빅데이터 5. 데이터 기술통계

기술통계 정의

- 수집한 자료에 대한 정리, 표현, 요약, 해석을 통해 자료의 특성을 규명
- 빈도분석, 기술분석, 교차분석, 다차원 척도법 등 포함

통계자료의 종류

자료 유형	척도	예시	특징
범주형	명목척도	성별, 결혼여부	다르다만 표시
	서열척도	선호·성적 순위	순서 있음, 양적비교 불가
연속형	등간척도	온도, 만족도	간격 동일, 절대점 없음
	비율척도	중량, 소득	절대점 있음, 사칙연산 가능

기술통계 기법

- 빈도분석: 범주형 → 빈도·비율 산출 → 막대그래프·파이차트 시각화
- 기술분석: 연속형 → 평균·중앙값·최빈수·분산·표준편차·왜도·첨도
- 교차분석: 2개 이상 범주형 → 교차 빈도 표 → 독립성 검정(카이제곱)
 - $\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$
- 다차원척도법(MDS): 자료 간 유사성 측정 → 2-3차원 공간 시각화
 - 유클리드 거리: $\sqrt{\sum_{i=1}^n (X_{1i} - X_{2i})^2}$

탐색적 자료분석(EDA)

- 가설검정보다 자료의 본연의 의미를 찾는 분석 기법
- 도구: 박스 플롯(이상치 파악), 산포도, 줄기 잎 도표, Q-Q 도표
- 박스 플롯: 최솟값, 1사분위수, 중앙값, 3사분위수, 최댓값 표시

빅데이터 6. 데이터 추론통계

추론통계 개념

- 표본 분석 → 모집단의 특성(모수) 추정 및 일반화
- 모집단: 정보를 얻고자 하는 대상 집단
- 모수: 모집단의 특성을 나타내는 정도
- 표본: 모집단으로부터 추출된 관측값

통계량과 모수

- 통계량: 표본의 특성값
- 모수: 모집단의 특성값
- 빅데이터 시대: 데이터가 모집단에 근접 → 기술통계만으로도 모수 추정 가능

가설검정 기본

- 귀무가설(H_0): “차이가 없다”, “효과가 없다” (지키고자 하는 가설)
- 대립가설(H_1): “차이가 있다”, “효과가 있다” (증명하고 싶은 가설)
- 유의확률(P-value): 귀무가설이 맞을 때 현재 데이터가 나타날 확률
- 판단: $P < 0.05$ → 귀무가설 기각 (통계적으로 유의), $P \geq 0.05$ → 귀무가설 채택

분석 기법 선택

대상	집단수	분석 방법	R 함수
평균 차이	2개	t-검정(t-test)	t.test()
평균 차이	3개 이상	분산분석(ANOVA)	aov(), anova()
비율 차이	2개 이상	비율차이/카이제곱	prop.test(), chisq.test()
변수 간 관계	2개 변수	상관분석	cor.test()

인과/영향력	다수 변수	회귀분석	lm()
--------	-------	------	------

평균차이분석 (t-검정)

- 두 집단 간 평균 차이가 통계적으로 유의한지 파악
- 독립표본 t-검정: 서로 다른 두 집단 비교 (예: 남 vs 여 만족도)
- 대응표본 t-검정: 동일 집단의 전/후 비교 (예: 다이어트 전/후 몸무게)

분산분석 (ANOVA)

- 3개 이상 집단의 평균 비교
- 집단 간 분산 vs 집단 내 분산 비교 → F-분포 활용
- F-값이 클수록 집단 간 차이가 큼
- 일원배치: $X \rightarrow Y$, 이원배치: $X, A \rightarrow Y$

상관분석

- 두 변수 간 관련성 정도 분석
- 상관계수(r): -1 ~ 1 범위
 - 1에 가까움: 양의 상관, -1에 가까움: 음의 상관, 0: 관계없음
- $r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}}$ 가 크게 변하는 정도

회귀분석

- 변수 간 인과관계를 규명
- 독립변수(X) → 종속변수(Y)
- 선형 회귀식: $Y = a + bX$
- 결정계수(R^2): 모델이 데이터를 설명하는 정도 (1에 가까울수록 좋음)
- 등간척도·비율척도 등 연속형 변수로 측정

확률분포

- 정규분포: 연속적·좌우대칭·종 모양 (대부분 자료 분포)
- t-분포: 모분산 미알 및 표본 수 작을 때 모평균 추정·검정
- F-분포: 표본 분산들의 비 분포 (분산분석, 회귀식 유의성 검정)
- χ^2 분포: 관찰 빈도와 기대 빈도 간 차이 검정

가설검정 절차

1. 가설 설정: H_0, H_1 정의
2. 적절한 검정통계량 계산
3. 유의수준 설정 (보통 0.05)
4. 표본으로부터 검정통계량 값 계산 → 유의확률(P-value) 계산
5. P-value와 유의수준 비교 → 귀무가설 기각 여부 결정
6. 검정결과 요약 기술

데이터마이닝 기법

분류분석 (Classification)

- 데이터를 사전 정의된 범주로 분류하는 기법
- 용도: 고객 신용도 등급(우수/보통/위험), 이메일 스팸 분류
- 주요 기법:
 - 나이브 베이즈(Naive Bayes): 확률 기반 분류, 빠르고 간단
 - 의사결정트리(Decision Tree): 규칙 기반, 해석 용이
 - 서포트 벡터 머신(SVM): 경계선 찾아 분류, 고차원 데이터 강점
 - 로지스틱 회귀: 확률 기반 분류
 - K-NN(K-Nearest Neighbors): 근처 데이터 기반 분류

예측분석 (Prediction)

- 과거 데이터 바탕으로 미래 값 예측
- 용도: 주가 예측, 판매량 예측, 이탈 고객 예측
- 주요 기법:
 - 회귀분석(Regression): 선형·비선형 관계 파악
 - 시계열분석(Time Series): 시간 흐름에 따른 추세 분석
 - 신경망(Neural Network): 복잡한 비선형 패턴 학습

군집분석 (Clustering)

- 유사한 개체들을 자동으로 그룹화
- 용도: 고객 세분화, 문서 분류, 유전자 분석
- 주요 기법:
 - K-means: 정해진 개수 k개로 분할, 반복적 최적화
 - 계층적 군집화(Hierarchical): 트리 구조로 군집 생성
 - DBSCAN: 밀도 기반 군집화, 이상치 자동 제거

연관분석 (Association)

- 변수 간 관계 규칙 발견
- 용도: 장바구니 분석(함께 구매하는 상품), 추천 시스템
- 주요 기법:
 - Apriori: 빈번한 항목집합 → 규칙 생성
 - 지표: 지지도(Support), 신뢰도(Confidence), 향상도(Lift)

텍스트마이닝 & 감성분석

텍스트마이닝

- 자연어처리(NLP) 기술로 비정형 텍스트에서 유용한 정보 추출
- 기법: 주제어 분석, 단어 간 연관성, 토픽 모델링, 오피니언 마이닝
- 절차:
 1. 텍스트 수집
 2. 전처리 (특수문자·종복 제거, 형태소 분석, 불용어 제거)
 3. 특징 추출 (단어 빈도, TF-IDF)
 4. 분석 및 모델링 (주제 추출, 감성 분석)
 5. 시각화 및 해석

감성분석 (Opinion Mining)

- 글쓴이의 의견·감정·태도 판별
- 결과: 긍정(Positive), 부정(Negative), 중립(Neutral)
- 절차:
 1. 텍스트 전처리
 2. 감성 사전 구축 (긍정/부정 단어 학습)
 3. 감성 점수 계산 → 분류
 4. 결과 해석
- 지표:
 - 정확도(Accuracy): 올바르게 분류한 비율
 - 정밀도(Precision): 긍정으로 분류한 중 실제 긍정 비율
 - 재현율(Recall): 실제 긍정 중 올바르게 분류한 비율
 - F1-Score: Precision과 Recall의 조화평균

소셜 네트워크 분석 (SNA)

- 사용자 간의 연결 구조 파악, 영향력 측정
- 그래프 종류:
 - 방향 그래프: 팔로우 관계 (A→B 팔로우)
 - 무방향 그래프: 친구 관계 (양방향)
 - 가중치 그래프: 상호작용 빈도 반영
- 주요 분석:
 - 중심성(Centrality): 연결 중심도, 근접 중심도, 매개 중심도
 - 커뮤니티 탐지: 밀집된 부분 그룹 찾기
 - 영향력 분석: 인플루언서 식별