

〈빅데이터의과학적탐구〉 제3차 리포트

공과대학 컴퓨터정보통신공학과
박종현(214823)

제3차 연습문제 답안

〈빅데이터의과학적탐구〉 과제 #3

박중현, 공과대학 컴퓨터정보통신공학과
jonghyeon@jnu.ac.kr

1. 빅데이터를 정의하고, 빅데이터의 3가지 특성에 대하여 설명하시오.

답안 빅데이터는 그 규모가 매우 크고 방대하여, 전통적인 데이터 처리 방식으로는 처리할 수 없는 유형의 데이터를 의미한다. 빅데이터와, 이들 데이터를 처리하기 위해 빅데이터 기술은 기존의 데이터 분석 관행과 데이터 분석의 패러다임을 바꿀 정도로 획기적이었다. 이전의 데이터 분석이 분석 작업을 치밀하게 설계하고, 인과관계를 밝히는 데 주력했다면, 빅데이터 처리 과정에서는 우선 데이터를 수집하면서, 그 안에서 새로운 통찰력을 얻거나, 데이터의 상관관계만으로도 새로운 직관을 획득할 수 있게 되었다.

빅데이터는 그 특징을 3V, 5V 등으로 표현한다. 기본적으로 3V라고 하는데, 규모(Volume), 다양성(Variety), 속도(Velocity)를 두고 규모가 크고, 매우 다양하며, 데이터의 수집, 분석, 활용 속도가 매우 빠르다는 특성이 있다고 서술된다. 여기서 확장하여 신뢰성(Veracity), 가치(Value)를 포함하여 5V라고 하거나, 휘발성(Volatility), 시각화(Visualization), 가변성(Variability) 등을 함께 언급하기도 한다.

2. 빅데이터의 데이터 종류인 정형, 반정형, 비정형 데이터에 대하여 설명하시오.

답안 정형, 반정형, 비정형 데이터는 데이터가 얼마나 정해진 형태가 되었는지에 따라 구분된다.

일반적으로 정형 데이터에는 그 구조에 엄격하고, 사전에 정의된 데이터 모델, 스키마가 있다. 정형 데이터 스토리지 시스템에서도 이들 상황을 충족할 수 있는 관계형 데이터베이스나 데이터 웨어하우스를 사용한다.

하지만 비정형 데이터의 경우에는 이와 같이 별도로 정의된 구조가 없고, 주로 비관계형 데이터베이스나 데이터 레이크에 저장하는 방식으로 활용한다.

때문에 정형 데이터가 비정형 데이터보다 조작하거나 분석하기 더 용이한데, 더 복잡한 상황을 표현하기에는 부적절할 수 있다.

반정형 데이터는 정형 데이터와 비정형 데이터의 중간 상태를 표현하는 명칭이다. 주로 사전 정의된 데이터 모델이나 스키마는 없지만, 다소 구조적인 데이터 형태를 띠고 있어, 이들 데이터 구조를 설명

하는 추가적인 메타데이터를 함께 다룬다. 주로 XML, JSON과 같은 형태로 다루어진다.

3. 빅데이터의 정형 데이터 분석 기법들인 기술통계 분석, 데이터마이닝에 대하여 약술하시오.

답안 기술통계 분석은 기술되는(Descriptive) 통계(Statistics)를 분석하는 기법으로, 수집된 데이터를 수치적으로 혹은 통계 기법을 사용해 데이터의 전반적인 특성을 파악하는 기법이다. 평균, 빈도 분석 등과 같은 설명값을 이용한다.

데이터 마이닝은 대규모의 데이터 속에서 유의미한 패턴이나 상관관계, 혹은 그 규칙을 찾아내어 미래를 예측하거나 지식을 추출하는 기법이다. 분류, 군집화, 연관 규칙 분석 등을 이용해 실현한다.

4. 빅데이터의 비정형 데이터 분석 기법들인 텍스트마이닝, 오피니언마이닝, 소셜네트워크 분석에 대하여 약술하시오.

답안 텍스트 마이닝은 자연어 처리 기술을 이용하여, 비정형 데이터인 텍스트 값에서 유용한 정보를 추출하는 기법이다.

오피니언 마이닝은 텍스트에서 사용자의 의견이나 감정 등을 추출, 분석하여 텍스트가 포함하고 있는 개별 사용자의 의견과 감정을 분석하는 기법이다.

소셜 네트워크 분석은 각 사용자 간의 관계, 연결 구조, 영향력 등을 그래프 이론을 통해 분석하는 기법이다.

5. 데이터 시각화 기법인 정보 시각화 과학적 시각화, 인포그래픽에 대하여 설명하시오.

답안 정보 시각화는 대규모의 비수치적 자료를 시각적으로 표현하여 정보를 쉽게 이해하도록 돕는 기법이다. 주로 막대그래프나 히트맵 등의 수단을 사용하여 구현한다.

과학적 시각화는 실험 데이터나 관측 데이터 등 물리적 수치를 시각화하는 기법이다. 기상도, 의료용 MRI 영상과 같이, 과학적 사실로부터 응용하여 필요한 데이터나 정보를 알기 쉽게 표현하는 것과 같이 구현한다.

인포그래픽은 정보(Information)를 그래픽(Graphics)으로 표현한다는 의미로 이와 같이 명

칭되었다. 복잡한 정보를 디자인 요소를 활용해 한 눈에 알기 쉽게 전달하는 데 목적이 있다.

6. 빅데이터의 분석 인프라 기술인 하둡에 대하여 설명하시오.

답안 빅데이터는 그 규모의 방대함으로 인해, 개별 컴퓨팅 기기로는 처리 성능에 있어 그 처리에 부족함이 있다. 하둡은 이를 보완하기 위해 분산 데이터 처리를 구현하는 것을 목표로 개발된 분산 컴퓨팅 인프라 시스템이다. 하둡은 인프라 시스템으로서 동작하므로, 실제로는 이 위에 하둡에 의존성을 갖는 각종 소프트웨어를 동작시켜 빅데이터 분석 시스템을 구성할 수 있다.

7. 빅데이터의 분석 인프라 기술인 R에 대하여 설명하시오.

답안 R은 통계 계산과 그래픽 처리를 위한 오픈소스 프로그래밍 언어와 소프트웨어 환경을 통칭한다. 어떤 데이터 세트에 대해 즉석으로 데이터가 표현하는 상황 등을 확인하는 데 초점을 두고 있다. 편의성과 고품질의 도구, CRAN을 이용해 기능을 추가하거나, 본인이 필요한 패키지를 생성할 수 있는 등의 특성으로, 데이터 과학자와 통계학자들 사이에서 널리 사용되고 있다.

8. 빅데이터의 분석 인프라 기술인 NOSQL에 대하여 설명하시오.

답안 NoSQL은 'Not only SQL'을 표방하여 관계형 데이터베이스 시스템과 이 시스템을 제어하는 데 사용하는 SQL을 사용하지 않고도 데이터를 조직하고 저장, 처리할 수 있게 하는 데 초점을 두고 있다. 데이터를 조직하는 방법에 리스트, 해시 테이블, 트리, 그래프 등의 다양한 방법을 통칭하는 표현으로 사용되는 경향이 있으나, 각각 명확한 장점과 단점이 있어 실제로는 구체적인 전략에 따라 전략적으로 선택하여 사용하게 된다.

대부분 클러스터에서 실행할 목적으로 만들어져, 관계형 모델을 사용하지 않는다. 그러나 모든 NoSQL 데이터베이스가 클러스터에서 실행되도록 맞춰진 것은 아니다. 예를 들어 NoSQL 데이터 모델 중 하나인 그래프 데이터베이스는 관계형 데이터베이스와 비슷한 분산 모델을 사용한다.

보통 21세기 초반 웹 환경의 필요에 기초를 두고 있어서, 이 시기에 개발된 시스템만을 NoSQL이라고 부른다. 따라서 그 이전에 만들어진 ODBMS(Objective Database Management System)은 NoSQL에 해당하지 않는다.

스키마 없이 동작하며, 구조에 대한 정의를 변경할 필요 없이 데이터베이스 레코드에 자유롭게 필드를 추가할 수 있다.

9. R의 탄생 및 발전 과정에 대하여 설명하시오.

답안 R은 1990년대 초반 뉴질랜드의 오클랜드 대학교의 로스 이하카와 로버트 젠틀맨이 S 언어를 기반으로 개발한 프로그래밍 언어이다. S 언어는 1970년대 미국 벨 연구소에서 통계 분석을 위해 개발되었는데, R은 이를 재구현한 것이다.

초기 R은 통계학자들 사이에서만 사용되었으나, 1997년 R 프로젝트가 공식적으로 시작되면서 오픈소스 프로젝트로서 본격적인 발전을 이루게 되었다. 이후 전 세계의 개발자들이 참여하여 패키지를 개발하고 기능을 확장하면서, 현재는 데이터 과학, 통계학, 금융 분석 등 다양한 분야에서 가장 널리 사용되는 통계 분석 도구 중 하나로 자리잡았다. 특히 CRAN이라는 중앙 저장소의 등장으로 수많은 전문화된 패키지들이 체계적으로 관리되고 배포되면서, R의 활용 범위는 점점 더 확대되고 있다.

10. R의 특징에 대하여 설명하시오.

답안 첫째, R은 오픈소스 프로그래밍 언어로서 누구나 자유롭게 사용할 수 있다. 소스 코드가 공개되어 있어 필요에 따라 수정하고 개선할 수 있다.

둘째, R은 통계 계산에 특화되어 있어 다양한 통계 분석 기법과 함수들이 기본으로 제공되어, 복잡한 통계 모델링도 용이하게 수행할 수 있다.

셋째, R은 강력한 그래픽 기능을 제공하여 데이터의 시각화를 직관적이고 효과적으로 수행할 수 있다.

넷째, CRAN을 통해 기여자들이 만든 수만 개의 패키지를 활용할 수 있다. 사용자들은 이들 패키지를 이용해 자신의 분석 능력을 확장할 수 있다.

다섯째, R은 데이터 분석에 있어 즉각적인 피드백을 제공하는 인터랙티브 환경을 제공하므로, 탐색적 데이터 분석에 매우 적합하다.