

〈빅데이터의과학적탐구〉 제4차 리포트

공과대학 컴퓨터정보통신공학과
박종현(214823)

제4차 연습문제 답안

〈빅데이터의과학적탐구〉 과제 #4

박종현, 공과대학 컴퓨터정보통신공학과
jonghyeon@jnu.ac.kr

1. R에서 `setwd("C:/WORK_R")`와 `getwd()` 명령에 대하여 설명하시오.

답안 `setwd`와 `getwd`의 `wd`는 Working Directory(워킹 디렉토리)라는 의미이다. `setwd`는 워킹 디렉토리의 setter, `getwd`는 워킹 디렉토리의 getter이다.

워킹 디렉토리는 R에서 코드를 실행할 때, 어떤 파일을 참조하거나, 파일을 쓰기 작업 하는 등 파일 입출력 작업을 수행될 때 기준이 되는 경로이다. 다시 말해 워킹 디렉토리 값이 다르면 같은 명령도 다른 결과를 낼 수 있다.

2. R 패키지에 대하여 설명하고, 설치 시 유의점에 대하여 설명하시오.

답안 R은 다른 사람이 미리 작성한 코드와 함수를 가져와 사용할 수 있게 하는 기능을 가지고 있다. 여기에 이어 이들 코드와 함수를 언어 인프라에서 저장하고 관리할 수 있게 했다.

사용자는 자신이 작성한 코드를 패키지라는 단위로 묶어, R 인프라 중 패키지 레지스트리인 CRAN에 공개할 수 있다. 또, R 기본 함수 스펙에 CRAN으로부터 패키지를 다운로드받는 함수 정의인 `install`, `install.packages`를 추가하여, R 코드 상에서 즉시 패키지를 다운로드받아 사용할 수 있게 했다.

패키지 생태계가 성숙해지고 기술이 고도화됨에 따라, 대개의 패키지는 다른 패키지에 의존성을 가지게 되었다. 만약 패키지를 설치하는 과정에서 어떤 두 패키지가 다른 버전의 같은 패키지에 의존성을 갖는다면 버전 충돌, 혹은 패키지 설치가 제대로 수행되지 않을 수 있다.

의존성 측면에서 모든 패키지는 R에 의존성을 가지는데, 대개는 문제가 없으나, R의 버전 상황에 따라서는 너무 오래된 패키지가 동작하지 않을 수 있다. 역으로 R이 너무 오래전 버전이라면, 개정된 표준이나 정의에 근거하는 최신 패키지가 제대로 동작하지 않을 수도 있다.

이들 패키지는 일반적으로 CRAN을 통해 다운로드받을 수 있지만, 최신 베타판, 혹은 몇 이유로 CRAN이 아니라 다른 경로를 통해 패키지가 배포되는 경우가 있을 수 있다. 이러한 경우 CRAN의 검수 절차를 거치지 않았기 때문에, 잠재적으로 오작동하거나 기기에 위험한 코드가 포함되어 있을

가능성이 있다. 설치 전에 이들 패키지가 정말 신뢰 가능한지 확인해야 한다.

3. R에서 1부터 999까지의 합계의 제곱근 값을 구하시오.

답안 706.7531

```
result <- 0
for (i in 1:999) {
  result <- result + i
}
result ** 0.5
```

의견

```
> result <- 0
> for (i in 1:999) {
+   result <- result + i
+ }
>
> result ** 0.5
[1] 706.7531
```

4. 다음 R에서 지원하는 자료 구조들에 대하여 설명하시오.

(1) 벡터

답안 벡터 값을 표현하는 자료형이다. 일반적으로 벡터의 이론적 정의와 동일하게 (3, 5)와 같은 값 표현에 사용한다. 때문에 모든 벡터는 요소가 모두 동일한 자료형인 1차원의 배열과 같은 형태이다. `c`함수를 이용해 생성할 수 있다.

```
c(1, 2, 3, 4, 5)
```

(2) 행렬

답안 행렬 값을 표현하는 자료형이다. 벡터가 2차원으로 확장되어 행과 열을 갖는 형태이다. 이 값은 `matrix`함수를 이용해 생성할 수 있다.

```
mat <- matrix(1:6, nrow = 2, ncol = 3)
```

(3) 배열

답안 3차원 이상의 데이터 구조를 표현할 수 있도록 의도된 자료형이다. `array`함수를 이용해 생성할 수 있다.

```
arr <- array(1:12, dim = c(2, 3, 2))
```

(4) 데이터프레임

답안 일종의 표, 엑셀 시트, 관계형 데이터베이스 테이블과 비슷한 개념으로 사용 가능한 자료형이다. 각 열은 벡터로 생성하여 동일한 자료형으로 구성되어야 하지만, 이들 열 사이에는 자료

형이 같지 않아도 된다. data.frame 함수로 생성한다.

```
name <- c("박종현", "오민서", "김강산")
age <- c(25, 24, 26)
dept <- c("컴퓨터", "산업", "일어일문")

df <- data.frame(이름 = name, 나이 = age, 학
과 = dept)
df
```

(5) 리스트

답안 리스트는 서로 다른 자료 구조와 서로 다른 데이터 타입을 모두 담을 수 있는 가장 유연한 자료 구조이다. list로 생성한다.

```
my_list <- list(
  vec = c(1, 2, 3),
  mat = matrix(1:4, 2, 2),
  df = data.frame(x = 1:2, y = c("A",
"B"))
)
```

(6) 요인

답안 팩터는 범주형 데이터를 표현하는 데 활용하는 것이 의도되는, 특별한 형태의 벡터이다.

```
gender_data <- c("남", "여", "남", "남",
"여")

gender_factor <- factor(gender_data)

print(gender_factor)
# [1] 남 여 남 남 여
# Levels: 남 여

print(as.numeric(gender_factor))
# [1] 1 2 1 1 2
```

5. 다음의 변수 a에서 두 번째 원소인 2를 산출하는 명령을 쓰시오.

```
a <- c(1, 2, 0.5, 3, 7, -2, 10)
```

답안 a[2]

6. 다음 값들의 합계, 평균, 표준편차, 최솟값, 최댓값을 R에서 구하시오.

```
54, 39.6, 51.6, 52.8, 51.6, 52.8, 54, 52.8,
16.8, 52.8, 52.8, 54
```

답안

- 합계: 585.6
- 평균: 48.8
- 표준편차: 10.8101
- 최솟값: 16.8
- 최댓값: 54

의견

```
> v <- c(54, 39.6, 51.6, 52.8, 51.6, 52.8,
54, 52.8, 16.8, 52.8, 52.8, 54)
> sum(v)
[1] 585.6
mean(v)
> mean(v)
```

```
[1] 48.8
sd(v)
> sd(v)
[1] 10.8101
> min(v)
[1] 16.8
> max(v)
[1] 54
```

7. 다음의 벡터 x값을 행렬 y값으로 변경하는 명령을 쓰시오.

```
x <- c(1, 2, 3, 4, 5, 6, 7, 8, 9)

y
[ ,1] [ ,2] [ ,3]
[1,] 1 4 7
[2,] 2 5 8
[3,] 3 6 9
```

답안 y <- matrix(x, nrow = 3)

8. 다음과 같은 데이터프레임 df를 벡터값들을 이용하여 생성하시오.

```
df
  x y z
1 1 red TRUE
2 2 white TRUE
3 3 blue TRUE
4 4 yellow FALSE
```

답안

```
_x <- c(1, 2, 3, 4)
_y <- c("red", "white", "blue", "yellow")
_z <- c(TRUE, TRUE, TRUE, FALSE)
```

```
df <- data.frame(x = _x, y = _y, z = _z)
df
```

9. 상기 데이터프레임 df에서 x행의 값들의 평균과 합계를 구하시오.

답안

- 평균: 2.5
- 합계: 10

의견

```
> mean(df$x)
[1] 2.5
> sum(df$x)
[1] 10
```

10. 상기 데이터프레임 df에서 행의 이름을 '숫자', '색상', '논릿값'으로 변경하시오.

답안

```
> colnames(df) <- c("숫자", "색상", "논릿값")
df
> df
  숫자  색상 논릿값
1    1   red  TRUE
2    2  white  TRUE
3    3   blue  TRUE
4    4 yellow FALSE
```