

〈빅데이터의과학적탐구〉 제8차 리포트

공과대학 컴퓨터정보통신공학과
박종현(214823)

제8차 연습문제 답안

〈빅데이터의과학적탐구〉 과제 #8

박종현, 공과대학 컴퓨터정보통신공학과
jonghyeon@jnu.ac.kr

1. 추론통계 기법인 평균 차이 분석, 비율 차이 분석, 분산분석, 상관관계 분석, 회귀분석에 대하여 설명하시오.

답안

- 평균 차이 분석 (t-검정): 두 집단 간의 평균이 통계적으로 유의미한 차이가 있는지 검정한다.
- 비율 차이 분석 (교차분석/ χ^2 -검정): 두 범주형 변수 간의 관련성이나 비율의 차이가 있는지 검정한다.
- 분산분석 (ANOVA): 세 집단 이상의 평균을 비교할 때 사용하며, 집단 내 분산 대비 집단 간 분산의 크기를 비교하여 차이를 검정한다.
- 상관관계 분석: 두 수치형 변수 간의 선형적 관련성, 강도와 방향을 분석한다. 이 때 사용되는 상관계수 r 은 -1 에서 1 사이의 값을 가진다.
- 회귀분석: 독립변수가 종속변수에 미치는 영향력을 모델링하고 예측하는 기법이다. 변수 간의 인과관계를 파악하는 데 주로 사용된다.

2. <http://ssra.or.kr.co.kr/bigdata/data.csv> 에서 data.csv 파일을 다운로드하여 R로 불러들여 `data` 라는 데이터프레임 변수로 만들고, 이 데이터프레임의 소득 변수에 대하여 성별 평균 차이 분석을 수행하고 결과를 해석하시오.

답안

```
data <- read.csv("data.csv")
t.test(data$소득 ~ data$성별)
```

Welch Two Sample t-test

```
data: data$소득 by data$성별
t = -0.28289, df = 80.512, p-value = 0.778
alternative hypothesis: true difference in means between group 남자 and group 여자 is not equal to 0
95 percent confidence interval:
 -891.0445  669.2263
sample estimates:
mean in group 남자 mean in group 여자
      5159.091      5270.000
```

소득과 성별 간 관계에 대해, p-value 0.778로 신뢰구간 95%에서 귀무가설을 기각할 수 없다. 따라서 두 변수는 독립이다.

3. 상기 데이터프레임에서 다음과 같이 만족 여부 변수를 생성한 후, 만족 여부에 대한 성별 비율 차이 분석을 수행하고 결과를 해석하시오.

```
data$만족여부 <- ifelse((data$쇼핑만족도 > 3), '만족', '불만족')
```

답안

```
data$만족여부 <- ifelse((data$쇼핑만족도 > 3), '만족', '불만족')
table(data$만족여부, data$성별)
```

	남자	여자
만족	53	31
불만족	2	4

```
chisq.test(table(data$만족여부, data$성별))
```

Pearson's Chi-squared test with Yates' continuity correction

```
data: table(data$만족여부, data$성별)
X-squared = 1.0227, df = 1, p-value = 0.3119

Warning message:
In chisq.test(table(data$만족여부, data$성별)) :
  Chi-squared approximation may be incorrect
```

만족 여부와 성별 간 관계에 대해, p-value 0.3119로 신뢰구간 95%에서 귀무가설을 기각할 수 없다. 따라서 두 변수는 독립이다.

4. 상기 데이터프레임의 소득 변수에 대하여 주거지역에 대한 분산분석을 수행하고 결과를 해석하시오.

답안

```
data$주거지역 <- as.factor(data$주거지역)
aov_result <- aov(data$소득 ~ data$주거지역)
summary(aov_result)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
data\$주거지역	2	2593896	1296948	0.367	0.694
Residuals	87	307840660	3538398		

주거지역과 소득 간 관계에 대해, p-value 0.694로 신뢰구간 95%에서 귀무가설을 기각할 수 없다. 따라서 두 변수는 독립이다.

5. 상기 데이터프레임의 쇼핑액과 쇼핑만족도 간의 상관관계 분석을 수행하고 결과를 해석하시오.

답안

```
cor.test(data$쇼핑액, data$쇼핑만족도)
```

Pearson's product-moment correlation

```
data: data$쇼핑액 and data$쇼핑만족도
t = 0.041531, df = 88, p-value = 0.967
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.2028499 0.2113246
sample estimates:
      cor
0.004427222
```

쇼핑액과 쇼핑만족도 간 관계에 대해, p-value 0.967로 신뢰구간 95%에서 귀무가설을 기각할 수 없다. 따라서 두 변수는 독립이다.

6. 상기 데이터프레임의 쇼핑액에 대한 소득, 이용만족도가 쇼핑만족도의 영향 유무를 알아보기 위한 회귀분석을 수행하고 결과를 해석하시오.

답안

```
lm_result <- lm(data$쇼핑만족도 ~ data$소득 + data$이용만족도)
summary(lm_result)
```

```
Call:
lm(formula = data$쇼핑만족도 ~ data$소득 + data$이용만족도)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-3.4518 -0.4372  0.2334  0.5949  2.5652
```

```
Coefficients:
```

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.667e+00  5.840e-01   2.854  0.00539 **
data$소득       2.430e-05  6.345e-05   0.383  0.70267
data$이용만족도 6.617e-01  8.342e-02   7.932 6.81e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.114 on 87 degrees of freedom
Multiple R-squared:  0.42,    Adjusted R-squared:  0.4067
F-statistic: 31.5 on 2 and 87 DF,  p-value: 5.108e-11

```

소득과 이용만족도가 쇼핑만족도에 미치는 영향에 대해, 소득의 p-value 0.70267로 신뢰구간 95%에서 귀무가설을 기각할 수 없다. 따라서 소득은 쇼핑만족도에 영향을 미치지 않는다.

반면 이용만족도의 p-value 6.81e-12로 신뢰구간 95%에서 귀무가설을 기각할 수 있다. 따라서 이용만족도는 쇼핑만족도에 영향을 미친다. 회귀모형의 R-squared 값이 0.42로, 이 모형이 쇼핑만족도의 변동성의 42%를 설명한다. F-statistic의 p-value 5.108e-11로, 이 모형이 유의미하다고 할 수 있다.