

〈빅데이터의과학적탐구〉 제11차 리포트

공과대학 컴퓨터정보통신공학과
박종현(214823)

제11차 연습문제 답안

<빅데이터의과학적탐구> 과제 #11

박종현, 공과대학 컴퓨터정보통신공학과
jonghyeon@jnu.ac.kr

1. 텍스트마이닝 기반인 주제어 분석, 동시 출현 단어 분석, 토픽 모델링, 감성 분석에 대하여 설명하시오.

답안 주제어 분석(키워드 추출, 주제어 분석)

- 문서 집합에서 핵심어·핵심 구문(문서의 주요 주제나 특징)을 자동으로 추출해 요약·색인·검색 등에 활용.
- 주요 방법
 - 통계기반: TF, TF-IDF(문서 중요도 반영), chi-square, mutual information 등.
 - 그래프 기반: TextRank(문장·단어를 노드로 그래프 구성, PageRank로 중요도 계산).
 - 규칙·의미 기반: 명사구 추출, 품사 패턴(예: Noun+Noun)·문장구조 활용.
 - 키워드 확장: RAKE(관계 기반 키프레이즈 추출).
- 절차: 토큰화 → 품사 필터링(명사·형용사 등) → 불용어 제거 → 어근화/정규화 → 가중치 계산 → 상위 키워드 선택
- 장단점: 간단·빠름(TF-IDF), 의미적 연결성은 약함(문맥 무시). TextRank는 문맥 반영 가능.
- 활용: 문서 요약, 색인, 태그 추천, 주제 탐색

동시 출현 단어 분석(Co-occurrence / Collocation)

- 동일 문서·문장·윈도우 내에서 함께 등장하는 단어 쌍(또는 집합)을 분석해 연관 관계·개념 네트워크를 파악.
- 주요 방법
 - 빈도 기반 동시출현 행렬(co-occurrence matrix).
 - 통계적 지표: PMI(pointwise mutual information), normalized PMI, log-likelihood ratio, χ^2 등.
 - 네트워크 분석: 단어를 노드, 동시출현을 엣지로 하는 그래프 생성 → 중심성·클러스터링 분석(community detection).
- 윈도우 크기(문장/고정 토큰 수) 설정이 중요.
- 절차: 전처리 → 윈도우 정의 → 동시출현 행렬 생성 → 가중치/스코어 계산 → 시각화(네트워크, 워드클라우드)
- 장단점: 의미적 연결·구조 파악에 유용(공동 등장 규칙), 희소성 문제 및 문맥의 방향성(원인·결과) 파악 어려움.
- 활용: 용어 네트워크, 개념 맵, 관계 추출, 토픽 전처리

토픽 모델링(Topic Modeling)

- 문서 집합에서 잠재적 주제(토픽)를 확률적·수학적으로 추출, 각 문서는 여러 토픽의 혼합으로 표현.
- 대표 알고리즘
 - LDA(Latent Dirichlet Allocation): 단어-토픽, 토픽-문서 분포를 베이지안으로 추정.
 - NMF(Non-negative Matrix Factorization): 문서-단어 행렬의 비음수 분해로 토픽 추출.
 - 시맨틱/임베딩 기반: BERTopic(문장임베딩 + 클러스터링 + 토픽 추출), Top2Vec 등.
- 절차: 전처리 → 단어행렬(BOW/TF-IDF) 구성 또는 문장 임베딩 → 모델 학습(토픽수 k 설정 필요) → 토픽 해석(상위 단어, 대표 문서) → 평가(퍼플렉시티, 토픽 응집도(C_v , UMass) 등)
- 장단점: 대량 문서에서 주제 구조 발견에 강함. 토픽 수 선정, 해석(주관성), 짧은 문서 처리(트위터 등)에서 성능 문제.
- 활용: 문서 분류 보조, 콘텐츠 분석, 트렌드 탐지, 추천시스템의 주제 피처

감성 분석(Sentiment Analysis / Opinion Mining)

- 정의/목적: 문장·문서에서 감정(긍정/부정/중립) 또는 더 세부적인 감정(기쁨·슬픔·분노 등)을 자동 분류 또는 수치화.
- 접근법
 - 룰/사전 기반: 감성사전(lexicon)과 규칙(부정어 처리, 강조부사). 간단하고 라벨이 없어도 사용 가능.
 - 지도학습 기반: 전통 ML(SVM, Logistic Regression) 혹은 딥러닝(RNN, CNN, Transformer)으로 문장 레이블 학습.
 - 하이브리드: 사전 기반 + 머신러닝
- 전처리·문맥 고려: 부정어 역전("not good"), 이모티콘/이모지, 문장 연결, 어조(강조·비꼼) 처리 필요.
- 평가 지표: Accuracy, Precision/Recall/F1, ROC-AUC(다중 클래스에선 매크로/마이크로 F1).
- 장단점: 사전 기반은 라벨 불필요하지만 도메인 적응성 낮음. 딥러닝은 정확도 높지만 데이터·자원 필요.
- 활용: 고객 리뷰 분석, 소셜 미디어 모니터링, 브랜드 감정 추이 분석

2. 텍스트마이닝의 자연어 처리 기술에 대하여 설명하시오.

답안 • 토큰화(Tokenization)

영어: 공백·구두점 기준; 한국어: 형태소 기반 토큰화(어간·어미 분리) 필요(예: Mecab, Kkma, Okt).

- 형태소 분석(Morphological analysis)

교착어(한국어 등)는 어근·접사 분리, 품사(POS) 태깅이 중요. 의미 추출·어간 통일에 필수.

- 품사 태깅(POS tagging) 및 구문 분석(Parsing)

품사 필터링(명사·동사 등), 의존구문 분석으로 관계 추출(주어·목적어 등).

- 정규화(Normalization) 및 텍스트 클린징

소문자화, 조사·특수문자 제거, 영어 약어 정리, 오타 교정 등.

- 불용어 제거(Stopword removal), 어간 추출(Stemming) 및 표제어 추출(Lemmatization)

불필요한 빈도 높은 단어 제거, 표제어로 통일해 희소성 감소.

- NER(명명 엔터티 인식)

인물·조직·장소·수치 등 추출 → 정보 추출·관계 분석에 사용.

- 문장 분할(Sentence segmentation) 및 문장 임베딩

문장 단위 분석을 위해 필수. 문장 임베딩은 문장 수준 의미를 보존(예: SBERT).

- 단어·문장 임베딩(Representation)

희소표현(BOW, TF-IDF)과 밀집임베딩(Word2Vec, GloVe, FastText, contextual BERT 계열).

- 의미중심 기법: Word sense disambiguation, coreference resolution

다의어 해소, 지시대명사 해석으로 정확도 개선.

- 토픽·요약·관계추출 관련 기법

토픽 모델링, 추출적/추상적 요약, 관계 추출(정보 추출).

- 전이학습(Pretrained language models)

BERT, RoBERTa, 한국어 전용 모델(한국어 BERT/KcBERT 등)로 하위 태스크(감성, NER 등) 미세조정(fine-tuning).

3. 공간 벡터 모델링 기술에 대하여 설명하시오.

답안 문서/문장/단어를 수치 벡터로 변환해서 수학적·기하학적으로 다루는 기술로, 벡터 공간에서의 거리·유사도를 통해 의미 유사성·클러스터링·검색 등을 수행할 수 있다.

4. 행정안전부 국가기록원 대통령기록관(<http://pa.go.kr/research/contents/speech/index.jsp>)에서 초대 대통령인 이승만 대통령의 취임사를 가지고 주제어 분석을 수행하시오.

답안

```
# 1. Getting Started
packages <- c("tidytext", "dplyr", "ggplot2", "wordcloud", "tm",
              "topicmodels", "stringr", "igraph", "ggraph", "tidyr", "purrr")

for (pkg in packages) {
  if (!require(pkg, character.only = TRUE)) {
    install.packages(pkg)
    library(pkg, character.only = TRUE)
  }
}

# install.packages("remotes")
```

```

# library("remotes")
Sys.setenv("JAVA_HOME"="/opt/homebrew/Cellar/sdkman-cli/5.19.0/libexec/candidates/java/11.0.31-amzn")
dyn.load("/opt/homebrew/Cellar/sdkman-cli/5.19.0/libexec/candidates/java/11.0.31-amzn/lib/server/libjvm.dylib")
# remotes::install_github('haven-jeon/KoNLP', upgrade = "never", INSTALL_opts=c("--no-multiarch"))
library("KoNLP")
Sys.setlocale("LC_ALL", "ko_KR.UTF-8")

library("showtext")
font_add_google("Noto Sans KR", family = "Noto Sans KR")
showtext_auto()

# 2. 데이터 전처리
speech_text <- readLines("./data/inaugural-speech-lee-sm.txt", encoding = "UTF-8")

# 한글과 공백만 보존
cleaned_text <- speech_text %>%
  str_remove_all("[^가-힣\\s]") %>%
  str_trim()

# 분리
full_text <- paste(cleaned_text, collapse = " ") # 전체를 하나의 문자열로 합침
sentences <- unlist(str_split(full_text, "\\s{2,}")) # 공백 2개 이상 기준으로 분리
sentences <- str_trim(sentences)
sentences <- sentences[nchar(sentences) >= 5] # 너무 짧은 토막 제외

text_df <- data.frame(
  doc_id = seq_along(sentences),
  text = sentences,
  stringsAsFactors = FALSE
)

# 토큰화 (형태소 분석)
library(KoNLP)

# 한국어 명사 추출
words_list <- lapply(seq_along(sentences), function(i) {
  nouns <- extractNoun(sentences[i])
  if (length(nouns) == 0) return(NULL)
  data.frame(
    doc_id = i,
    word = nouns,
    stringsAsFactors = FALSE
  )
})

words_df <- bind_rows(words_list) %>%
  filter(nchar(word) >= 2)

# 3. 불용어 제거
stopwords_korean <- c("이", "그", "저", "것", "수", "등", "같", "때", "그러나", "하여",
  "또한", "따라", "우리", "우리가", "있", "있다", "되", "되다",
  "이다", "있는", "되는", "하는", "말", "따라서", "그리고",
  "나의", "그러면", "그런데", "있게", "내가", "한다", "한")

words_cleaned <- words_df %>%
  filter(!word %in% stopwords_korean) %>%
  filter(nchar(word) >= 2)

# 4. 단어 빈도 분석
word_freq <- words_cleaned %>%
  group_by(word) %>%

```

```

summarise(frequency = n(), .groups = "drop") %>%
arrange(desc(frequency)) %>%
head(30)

print(word_freq)

# 시각화: 상위 20개 키워드 막대 그래프
word_freq %>%
  head(20) %>%
  ggplot(aes(x = reorder(word, frequency), y = frequency)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  labs(x = "키워드", y = "빈도") +
  theme_minimal() +
  theme(text = element_text(family = "HanSans"))

# 5. 단어 구름
library(wordcloud)

wordcloud(
  words = word_freq$word,
  freq = word_freq$frequency,
  min.freq = 2,
  max.words = 100,
  random.order = FALSE,
  rot.per = 0.2,
  colors = brewer.pal(8, "Dark2"),
  family = "HanSans"
)

# 6. 동시 출현 분석
library(igraph)

# 문장 내 동시 출현 단어 쌍 추출
cooccurrence_matrix <- words_cleaned %>%
  group_by(doc_id) %>%
  summarise(words = list(unique(word)), .groups = "drop") %>%
  filter(lengths(words) >= 2) %>% # 단어가 1개뿐인 문장 제외 (combn 오류 방지)
  mutate(pairs = map(words, function(x) {
    pairs_mat <- combn(x, 2, simplify = TRUE)
    data.frame(
      V1 = pairs_mat[1, ],
      V2 = pairs_mat[2, ],
      stringsAsFactors = FALSE
    )
  })) %>%
  select(doc_id, pairs) %>%
  unnest(pairs) %>%
  group_by(V1, V2) %>%
  summarise(count = n(), .groups = "drop")

# 네트워크 그래프 생성 (상위 30개 동시 출현 관계)
top_cooccurrence <- cooccurrence_matrix %>%
  arrange(desc(count)) %>%
  head(30)

g <- graph_from_data_frame(
  top_cooccurrence[, c("V1", "V2", "count")],
  directed = FALSE
)

# 네트워크 시각화
layout <- layout_with_fr(g)

```

```

plot(g,
     vertex.size = degree(g) * 2,
     vertex.label.cex = 0.8,
     vertex.label.family = "NotoSansKR",
     edge.width = E(g)$count / 10,)

# 7. 주제 모델링
library(topicmodels)

# DTM(Document-Term Matrix) 생성
dtm <- words_cleaned %>%
  group_by(doc_id, word) %>%
  summarise(count = n(), .groups = "drop") %>%
  cast_dtm(doc_id, word, count)

# LDA 모델 적용 (3개 주제)
lda_model <- LDA(dtm, k = 3, control = list(seed = 1234))

# 주제별 상위 10개 키워드 추출
topics <- tidy(lda_model, matrix = "beta")

top_terms <- topics %>%
  group_by(topic) %>%
  top_n(10, beta) %>%
  arrange(topic, -beta)

print(top_terms)

# 주제별 키워드 시각화
top_terms %>%
  mutate(term = reorder_within(term, beta, topic)) %>%
  ggplot(aes(beta, term, fill = factor(topic))) +
  geom_col(show.legend = FALSE) +
  facet_wrap(~topic, scales = "free") +
  scale_y_reordered() +
  labs(title = "LDA 주제 모델링: 주제별 상위 키워드",
       x = "Beta (확률)", y = "키워드") +
  theme_minimal() +
  theme(text = element_text(family = "HanSans"))

# 문서별 주제 비율 추출
doc_topics <- tidy(lda_model, matrix = "gamma")
print(doc_topics)

# 8. TF-IDF 분석 (주요도 측정)
cat("전체 행 수:", nrow(tfidf_analysis), "\n")
cat("tf_idf > 0 행 수:", sum(tfidf_analysis$tf_idf > 0), "\n")
print(summary(tfidf_analysis$tf_idf))
print(head(tfidf_analysis, 10))

# TF-IDF 계산
tfidf_analysis <- words_cleaned %>%
  group_by(doc_id, word) %>%
  summarise(count = n(), .groups = "drop") %>%
  bind_tf_idf(word, doc_id, count) %>%
  arrange(desc(tf_idf))

# 상위 20개 고유도 높은 단어
top_tfidf <- tfidf_analysis %>%
  distinct(word, .keep_all = TRUE) %>%
  top_n(20, tf_idf)

print(top_tfidf)

```

```

# 시각화
top_tfidf %>%
  ggplot(aes(x = reorder(word, tf_idf), y = tf_idf)) +
  geom_bar(stat = "identity", fill = "coral") +
  coord_flip() +
  labs(title = "취임사 문맥 고유도 높은 키워드 (TF-IDF)",
        x = "키워드", y = "TF-IDF 값") +
  theme_minimal() +
  theme(text = element_text(family = "HanSans"))

# 9. 감정 분석
# 긍정/부정 단어 사전 정의
positive_words <- c("영광", "감격", "희망", "분발", "전진", "신성", "평화", "친선",
                    "사랑", "감사", "애국", "노력")
negative_words <- c("두려움", "어려움", "분열", "위기", "공산", "반대", "부패", "손실")

sentiment_analysis <- words_cleaned %>%
  mutate(sentiment = case_when(
    word %in% positive_words ~ "긍정",
    word %in% negative_words ~ "부정",
    TRUE ~ "중립"
  )) %>%
  group_by(sentiment) %>%
  summarise(count = n())



print(sentiment_analysis)


# 감정 분포 파이 차트
sentiment_analysis %>%
  ggplot(aes(x = "", y = count, fill = sentiment)) +
  geom_bar(stat = "identity") +
  coord_polar("y", start = 0) +
  scale_fill_manual(values = c("긍정" = "green", "부정" = "red", "중립" = "gray")) +
  labs() +
  theme_void() +
  theme(legend.position = "bottom", text = element_text(family = "NotoSansKR"))

# 10. 분석 결과 요약
# 분석 결과 정리
summary_report <- list(
  총_단어수 = nrow(words_cleaned),
  고유_단어수 = length(unique(words_cleaned$word)),
  평균_단어길이 = mean(nchar(words_cleaned$word)),
  상위_5개_키워드 = head(word_freq, 5)$word,
  주요_주제 = top_terms %>% group_by(topic) %>% summarise(keywords = paste(term, collapse = ",
  "))
)


# 리포트 출력
cat("총 단어수:", summary_report$총_단어수, "\n")
cat("고유 단어수:", summary_report$고유_단어수, "\n")
cat("상위 5개 핵심 키워드:", paste(summary_report$상위_5개_키워드, collapse = ", "), "\n")



```





LDA 주제 모델링: 주제별 상위 키워드





```
# A tibble: 30 × 2
  word frequency
<chr>      <int>
```

```

1 자리          7
2 사람          6
3 친선          6
4 해서          6
5 나라          5
6 세계          5
7 눈물          4
8 대우          4
9 동포          4
10 정부         4
# i 20 more rows
# i Use `print(n = ...)` to see more rows

```

```

# A tibble: 48 × 3
# Groups:   topic [3]
  topic term      beta
  <int> <chr>   <dbl>
1     1 1 눈물  0.0385
2     1 1 동포  0.0385
3     1 1 남여  0.0288
4     1 1 직책  0.0288
5     1 1 마음  0.0192
6     1 1 사람  0.0192
7     1 1 영광  0.0192
8     1 1 오늘  0.0192
9     1 1 책임  0.0192
10    1 1 맹서  0.0192
# i 38 more rows
# i Use `print(n = ...)` to see more rows

```

```

# A tibble: 18 × 3
  document topic      gamma
  <chr>      <int>   <dbl>
1 1          1 0.999
2 2          1 0.999
3 3          1 0.994
4 4          1 0.000314
5 5          1 0.000393
6 6          1 0.000178
7 1          2 0.000579
8 2          2 0.000373
9 3          2 0.00312
10 4          2 0.000314
11 5          2 0.000393
12 6          2 1.000
13 1          3 0.000579
14 2          3 0.000373
15 3          3 0.00312
16 4          3 0.999
17 5          3 0.999
18 6          3 0.000178

```

```

전체 행 수: 288
tf_idf > 0 행 수: 288
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.00559 0.01445 0.02560 0.03226 0.03200 0.25597

```

```

# A tibble: 10 × 6
  doc_id word      count    tf   idf tf_idf
  <int> <chr>    <int> <dbl> <dbl> <dbl>
1     3 3 것입니      1 0.143  1.79  0.256

```

2	3 대의원	1 0.143 1.79 0.256
3	3 대표	1 0.143 1.79 0.256
4	3 무소속	1 0.143 1.79 0.256
5	3 좌익색대로	1 0.143 1.79 0.256
6	3 주목	1 0.143 1.79 0.256
7	1 눈물	4 0.105 1.79 0.189
8	3 정당	1 0.143 0.693 0.0990
9	5 기관	3 0.0536 1.79 0.0960
10	2 직책	3 0.0508 1.79 0.0911

```
# A tibble: 20 × 6
  doc_id word      count      tf      idf tf_idf
  <int> <chr>    <int>    <dbl>    <dbl>    <dbl>
1     3  것입니      1 0.143  1.79  0.256
2     3  대의원      1 0.143  1.79  0.256
3     3  대표        1 0.143  1.79  0.256
4     3  무소속      1 0.143  1.79  0.256
5     3  좌익색대로  1 0.143  1.79  0.256
6     3  주목        1 0.143  1.79  0.256
7     1  눈물        4 0.105  1.79  0.189
8     3  정당        1 0.143  0.693 0.0990
9     5  기관        3 0.0536 1.79  0.0960
10    2  직책        3 0.0508 1.79  0.0911
11    6  친선        6 0.0484 1.79  0.0867
12    4  국회의원    3 0.0429 1.79  0.0768
13    4  의장        3 0.0429 1.79  0.0768
14    6  세계        5 0.0403 1.79  0.0722
15    5  가지        2 0.0357 1.79  0.0640
16    5  낭설        2 0.0357 1.79  0.0640
17    5  조직        2 0.0357 1.79  0.0640
18    5  자리        5 0.0893 0.693 0.0619
19    2  맹서        2 0.0339 1.79  0.0607
20    2  하기        2 0.0339 1.79  0.0607
```

```
# A tibble: 3 × 2
  sentiment count
  <chr>      <int>
1 긍정        24
2 부정         5
3 중립       325
```

총 단어수: 354
고유 단어수: 246
상위 5개 핵심 키워드: 자리, 사람, 친선, 해서, 나라

5. RISS 학술연구정보서비스(<http://www.riss.kr/>)에서 ‘빅데이터 분석’을 키워드로 검색을 수행하여 관련 논문 제목들을 수집한 후, 논문 제목에서 동시 출현 단어 분석을 수행하시오.

답안

```
const arr = []; for (const each of document.querySelectorAll(".srchResultListW li p.title"))
{ arr.push(each.textContent) }
```

['[07 부산광역시 수영구] 읍면동 단위 빅데이터 분석을 통한 체계적 복지행정 구현', '[04 서울특별시 광진구] 해충발생 예측 및 방역 최적화 빅데이터 분석', '[05 강원도 춘천시] 빅데이터로 본 코로나19 발생 전후 주요 지역 상권 분석', '[06 충청남도 당진시] 버스정류장 승하차 현황 및 노선최적화 빅데이터 분석', '[08 경기도 가평군] 수난 사고 현황 빅데이터 분석', '2021 지방자치단체 빅데이터 분석 자료집 목차', '[05 서울특별시 동대문구] 1인 가구 빅데이터 분석', '[02 대전광역시] 임신·출산 정책 수립을 위한 빅데이터 분석', '[01 서울특별시 광진구] 바닥형 보행신호등 최적입지 선정 빅데이터 분석', '[05 서울특별시 광진구] 길고양이 민원 빅데이터 분석', '[07 충청남도 당진시] 종자 신청·공급 빅데이터 분석', '[02 경상북도] 경상북도 지역화폐 빅데이터 분석', '[03 서울특별시 성동구] 성동형 15분 도시 데이터 분석', '[09 경기도 하남시] 하남시

공공도서관 데이터 분석', '[03 서울특별시 종로구] 데이터기반 종로구 1인가구 분석', '[08 경상남도 양산시] 인공지능 및 민간 클라우드 데이터를 융합한 지역축제 분석', '소셜 빅데이터 분석 서비스 : 비정형 텍스트 빅데이터 분석과 응용 서비스', '모빌리티 빅데이터 가상결합 분석방법론 연구', '그래프 구조를 갖는 서지 빅데이터의 효율적인 온라인 탐색 및 분석을 지원하는 그래픽 인터페이스 개발', '빅데이터 분석을 위한 파티션 기반 시각화 알고리즘', '정책 분석 및 평가의 일관성 제고를 위한 빅데이터 분석 기반 지속가능발전의 현상학적 정의', '워게임 시뮬레이션 환경에 맞는 빅데이터 분석을 위한 분산처리기술', '특허분석을 통한 빅데이터 기술개발 동향', '빅데이터 환경에서 분석 자원이 기업 성과에 미치는 영향', '빅데이터 분석을 통한 기존 변화에 따른 상품의 판매량 분석', '빅데이터 분석을 이용한 기존 변화에 대한 판매량 예측 모델', '코로나로 인한 관광분야 대응을 위한 시사점 고찰 : 연구동향과 언론기사 빅데이터 분석을 중심으로', '유네스코학교 세계시민교육 우수사례 빅데이터 분석', '네이버 스마트스토어에 대한 빅데이터 분석 및소상공인 온라인쇼핑물 지속성장 방안 제안', '데이터베이스 연동을 통한 빅데이터 분석결과 가시화', '소셜 빅데이터 이슈 탐지 및 예측분석 기술 동향', '빅데이터 분석을 활용한 서울시 D구의 문화다양성 인식 연구', '디지털 오일필드에서 빅데이터 분석기반 IT 융합 기술 동향', '빅데이터를 활용한 공공계약의 입찰참가자수 영향요인 분석', '영상 빅데이터 분석기술 동향', '하이브리드 빅데이터 분석을 통한 홍수 재해 예측 및 예방', '공공연구성과 실용화를 위한 데이터 기반의 기술 포트폴리오 분석: 빅데이터 및 인공지능 분야를 중심으로', '빅데이터 기반의 모빌리티 분석', 'Visual Cell : 바이오세포 이미지 빅데이터를 위한 이미지 분석 및 시각적 검색 시스템', 'A 은행 사례 분석을 통한 빅데이터 기반 자금세탁방지 시스템 설계', '제조 공정 분석을 위한 빅데이터 클라우드 서비스', '빅데이터 기반 산학협력 네트워크 분석', '교육중단연구 분석을 위한 빅데이터 플랫폼 개발 및 적용', '재난 위험신고 빅데이터를 활용한 사회연결망 분석', '빅데이터 분석을 통한 천만 관객 영화 예측 모델', '빅데이터 분석을 통한 영화 관객수, 매출액 예측 모델', '정신분석과 빅데이터와의 대화 가능성 : 감정을 어떻게 처리할 것인가?에 관한 토론회', '빅데이터 분석 교육 프로그램을 통한 대학 교육 가치 창출', '빅데이터 기반의 화물운송 효율성 분석 방법론 개발', '의료기관 빅데이터 품질관리의 필요성과 사례 분석']

```
library(tidyverse)
library(KoNLP)
library(igraph)
library(ggraph)
library(tidygraph)
library(showtext)

font_add_google("Noto Sans KR", "notokr")
showtext_auto()

# -----
# 1. 수집된 논문 제목 데이터 입력
# -----

titles <- c(
  '[07 부산광역시 수영구] 읍면동 단위 빅데이터 분석을 통한 체계적 복지행정 구현',
  '[04 서울특별시 광진구] 해충발생 예측 및 방역 최적화 빅데이터 분석',
  '[05 강원도 춘천시] 빅데이터로 본 코로나19 발생 전후 주요 지역 상권 분석',
  '[06 충청남도 당진시] 버스정류장 승하차 현황 및 노선최적화 빅데이터 분석',
  '[08 경기도 가평군] 수난 사고 현황 빅데이터 분석',
  '2021 지방자치단체 빅데이터 분석 자료집 목차',
  '[05 서울특별시 동대문구] 1인 가구 빅데이터 분석',
  '[02 대전광역시] 임신·출산 정책 수립을 위한 빅데이터 분석',
  '[01 서울특별시 광진구] 바닥형 보행신호등 최적입지 선정 빅데이터 분석',
  '[05 서울특별시 광진구] 길고양이 민원 빅데이터 분석',
  '[07 충청남도 당진시] 종자 신청·공급 빅데이터 분석',
  '[02 경상북도] 경상북도 지역화폐 빅데이터 분석',
  '[03 서울특별시 성동구] 성동형 15분 도시 데이터 분석',
  '[09 경기도 하남시] 하남시 공공도서관 데이터 분석',
  '[03 서울특별시 종로구] 데이터기반 종로구 1인가구 분석',
  '[08 경상남도 양산시] 인공지능 및 민간 클라우드 데이터를 융합한 지역축제 분석',
  '소셜 빅데이터 분석 서비스 : 비정형 텍스트 빅데이터 분석과 응용 서비스',
  '모빌리티 빅데이터 가상결합 분석방법론 연구',
  '그래프 구조를 갖는 서지 빅데이터의 효율적인 온라인 탐색 및 분석을 지원하는 그래픽 인터페이스 개발',
  '빅데이터 분석을 위한 파티션 기반 시각화 알고리즘',
  '정책 분석 및 평가의 일관성 제고를 위한 빅데이터 분석 기반 지속가능발전의 현상학적 정의',
  '워게임 시뮬레이션 환경에 맞는 빅데이터 분석을 위한 분산처리기술',
  '특허분석을 통한 빅데이터 기술개발 동향',
  '빅데이터 환경에서 분석 자원이 기업 성과에 미치는 영향',
  '빅데이터 분석을 통한 기존 변화에 따른 상품의 판매량 분석',
  '빅데이터 분석을 이용한 기존 변화에 대한 판매량 예측 모델',
  '코로나로 인한 관광분야 대응을 위한 시사점 고찰 : 연구동향과 언론기사 빅데이터 분석을 중심으로',
  '유네스코학교 세계시민교육 우수사례 빅데이터 분석',
  '네이버 스마트스토어에 대한 빅데이터 분석 및소상공인 온라인쇼핑물 지속성장 방안 제안',
  '데이터베이스 연동을 통한 빅데이터 분석결과 가시화',
```

```

'소셜 빅데이터 이슈 탐지 및 예측분석 기술 동향',
'빅데이터 분석을 활용한 서울시 D구의 문화다양성 인식 연구',
'디지털 오일필드에서 빅데이터 분석기반 IT 융합 기술 동향',
'빅데이터를 활용한 공공계약의 입찰참가자수 영향요인 분석',
'영상 빅데이터 분석기술 동향',
'하이브리드 빅데이터 분석을 통한 홍수 재해 예측 및 예방',
'공공연구성과 실용화를 위한 데이터 기반의 기술 포트폴리오 분석: 빅데이터 및 인공지능 분야를 중심으로',
'빅데이터 기반의 모빌리티 분석',
'Visual Cell : 바이오세포 이미지 빅데이터를 위한 이미지 분석 및 시각적 검색 시스템',
'A 은행 사례 분석을 통한 빅데이터 기반 자금세탁방지 시스템 설계',
'제조 공정 분석을 위한 빅데이터 클라우드 서비스',
'빅데이터 기반 산학협력 네트워크 분석',
'교육중단연구 분석을 위한 빅데이터 플랫폼 개발 및 적용',
'재난 위험신고 빅데이터를 활용한 사회연결망 분석',
'빅데이터 분석을 통한 천만 관객 영화 예측 모델',
'빅데이터 분석을 통한 영화 관객수, 매출액 예측 모델',
'정신분석과 빅데이터와의 대화 가능성 : 감정을 어떻게 처리할 것인가?에 관한 토론편',
'빅데이터 분석 교육 프로그램을 통한 대학 교육 가치 창출',
'빅데이터 기반의 화물운송 효율성 분석 방법론 개발',
'의료기관 빅데이터 품질관리의 필요성과 사례 분석'
)

cat("수집된 논문 수:", length(titles), "\n")

# -----
# 2. 전처리: 대괄호·영문·숫자·특수문자 제거
# -----
titles_clean <- titles %>%
  str_remove_all("\\[.*?\\]") %>% # [07 부산광역시 수연구] 형태 제거
  str_remove_all("[A-Za-z0-9]") %>% # 영문·숫자 제거
  str_remove_all("[^가-힣\s]") %>% # 한글·공백 외 제거
  str_squish() # 연속 공백 정리

# -----
# 3. KoNLP 명사 추출 (doc_id 보존)
# -----
useNIADic()

# 불용어 정의 (분석 목적과 무관한 조사·어미·범용어)
stopwords <- c(
  "빅데이터", "분석", "기반", "위한", "통한", "활용", "관련",
  "연구", "개발", "것이", "경우", "이용", "대한", "관한",
  "위해", "통해", "따른", "대한", "중심", "방법", "결과",
  "방안", "현황", "적용", "수립"
)

words_list <- lapply(seq_along(titles_clean), function(i) {
  nouns <- extractNoun(titles_clean[i])
  if (length(nouns) == 0) return(NULL)
  data.frame(doc_id = i, word = nouns, stringsAsFactors = FALSE)
})

words_df <- bind_rows(words_list) %>%
  filter(nchar(word) >= 2) %>% # 2글자 미만 제거
  filter(!word %in% stopwords) # 불용어 제거

cat("추출된 단어 수:", nrow(words_df), "\n")
cat("고유 단어 수:", length(unique(words_df$word)), "\n")

# -----
# 4. 단어 빈도 확인
# -----
word_freq <- words_df %>%
  count(word, sort = TRUE)

```

```

cat(capture.output(as.data.frame(head(word_freq, 20))), sep = "\n")

# -----
# 5. 동시 출현 단어 쌍 추출
# -----
cooccurrence_matrix <- words_df %>%
  group_by(doc_id) %>%
  summarise(words = list(unique(word)), .groups = "drop") %>%
  filter(lengths(words) >= 2) %>%
  mutate(pairs = map(words, function(x) {
    x_sorted <- sort(x) # 쌍의 순서 통일 (A-B == B-A)
    pairs_mat <- combn(x_sorted, 2, simplify = TRUE)
    data.frame(
      V1 = pairs_mat[1, ],
      V2 = pairs_mat[2, ],
      stringsAsFactors = FALSE
    )
  })) %>%
  select(doc_id, pairs) %>%
  unnest(pairs) %>%
  group_by(V1, V2) %>%
  summarise(count = n(), .groups = "drop") %>%
  arrange(desc(count))

cat("\n상위 동시 출현 단어 쌍:\n")
print(cooccurrence_matrix, n = 20)

# -----
# 6. 시각화 (1) - 동시 출현 빈도 상위 막대그래프
# -----
top_pairs_bar <- cooccurrence_matrix %>%
  slice_max(count, n = 15, with_ties = FALSE) %>%
  mutate(pair_label = paste(V1, "-", V2))

ggplot(top_pairs_bar, aes(x = reorder(pair_label, count), y = count)) +
  geom_bar(stat = "identity", fill = "#4C72B0", width = 0.7) +
  geom_text(aes(label = count), hjust = -0.3, size = 3.5, family = "notokr") +
  coord_flip() +
  labs(
    title = "RISS 논문 제목 동시 출현 단어 쌍 Top 15",
    subtitle = "검색 키워드: '빅데이터 분석' (n = 50편)",
    x = "단어 쌍",
    y = "동시 출현 빈도"
  ) +
  theme_minimal(base_family = "notokr") +
  theme(
    plot.title = element_text(size = 14, face = "bold"),
    plot.subtitle = element_text(size = 10, color = "gray50"),
    axis.text = element_text(size = 10)
  )

# -----
# 7. 시각화 (2) - 동시 출현 네트워크 그래프
# -----
# 네트워크 구성 (2회 이상 동시 출현 쌍만 사용)
network_pairs <- cooccurrence_matrix %>%
  filter(count >= 2)

cat("네트워크 엣지 수:", nrow(network_pairs), "\n")

# 노드 중요도: 연결 강도 합산
node_strength <- bind_rows(
  network_pairs %>% select(word = V1, count),
  network_pairs %>% select(word = V2, count)
) %>%

```

```

group_by(word) %>%
summarise(strength = sum(count), .groups = "drop")

graph_data <- tbl_graph(
  edges = network_pairs %>% rename(from = V1, to = V2, weight = count),
  directed = FALSE
) %>%
  activate(nodes) %>%
  left_join(node_strength, by = c("name" = "word"))

set.seed(42) # 레이아웃 재현성 고정

ggraph(graph_data, layout = "fr") +
  geom_edge_link(
    aes(width = weight, alpha = weight),
    color = "steelblue",
    show.legend = FALSE
  ) +
  geom_node_point(
    aes(size = strength),
    color = "coral",
    alpha = 0.85
  ) +
  geom_node_text(
    aes(label = name),
    repel = TRUE,
    size = 3.5,
    family = "notokr",
    fontface = "bold"
  ) +
  scale_edge_width(range = c(0.5, 3)) +
  scale_size(range = c(3, 10)) +
  labs(
    title = "RISS 논문 제목 동시 출현 단어 네트워크",
    subtitle = "검색 키워드: '빅데이터 분석' | 동시 출현 빈도 ≥ 2",
    size = "연결 강도"
  ) +
  theme_void(base_family = "notokr") +
  theme(
    plot.title = element_text(size = 14, face = "bold", hjust = 0.5),
    plot.subtitle = element_text(size = 10, color = "gray50", hjust = 0.5),
    legend.position = "bottom"
  )

```

수집된 논문 수: 50
추출된 단어 수: 211
고유 단어 수: 174

	word	n
1	예측	6
2	기술	5
3	데이터	5
4	교육	4
5	사례	3
6	가구	2
7	관객	2
8	기온	2
9	모빌리티	2
10	발생	2
11	방법론	2
12	변화	2
13	분야	2
14	소셜	2

```
15     영화 2
16     융합 2
17     이미지 2
18 인공지능 2
19     정책 2
20     지역 2
```

상위 동시 출현 단어 쌍:

A tibble: 411 × 3

	V1	V2	count
	<chr>	<chr>	<int>
1	관객	영화	2
2	관객	예측	2
3	기온	변화	2
4	기온	판매량	2
5	데이터	인공지능	2
6	변화	판매량	2
7	영화	예측	2
8	가구	데이터	1
9	가구	종로구	1
10	가능성	감정	1
11	가능성	것인가에	1
12	가능성	대화	1
13	가능성	정신	1
14	가능성	처리	1
15	가능성	토론	1
16	가상	결합	1
17	가상	모빌리티	1
18	가상	방법론	1
19	가시	데이터베이스	1
20	가시	연동	1


i 391 more rows

i Use `print(n = ...)` to see more rows

네트워크 엣지 수: 7


RISS 논문 제목 동시 출현 단어 쌍 Top

검색 키워드: '빅데이터 분석' (n = 50편)



RISS 논문 제목 동시 출현 단어 네트워크

검색 키워드: '빅데이터 분석' | 동시 출현 빈도 ≥ 2



6. 5번에서 수집한 자료에 대하여 토픽 모델링을 수행하시오.

답안

```

remotes::install_github("nikita-moor/ldatuning")
library(ldatuning)

cat("사용 문서 수:", length(unique(words_df$doc_id)), "\n")
cat("사용 단어 수:", nrow(words_df), "\n")

# 단어 빈도 집계
dtm_df <- words_df %>%
  count(doc_id, word, name = "freq")

# tidytext → DTM 변환
dtm <- dtm_df %>%
  cast_dtm(document = doc_id,
            term     = word,
            value    = freq)

total_cells <- nrow(dtm) * ncol(dtm)
nonzero_cells <- sum(dtm$v != 0) # 실제 0이 아닌 셀 수
sparsity_manual <- 1 - (nonzero_cells / total_cells)

cat("DTM 행(문서) 수:", nrow(dtm), "\n")
cat("DTM 열(단어) 수:", ncol(dtm), "\n")
cat("DTM 희소성:", round(sparsity_manual, 4), "\n")

# 비어있는 행(단어가 전혀 없는 문서) 제거
rowsum_check <- slam::row_sums(dtm)
dtm_clean <- dtm[rowsum_check > 0, ]
cat("정제 후 문서 수:", nrow(dtm_clean), "\n")

# ldatuning으로 k = 2 ~ 10 범위 탐색
# ※ 문서 수가 적으므로 k 범위를 좁게 설정
set.seed(42)

result_metrics <- FindTopicsNumber(
  dtm_clean,
  topics = 2:8,
  metrics = c("Griffiths2004", "CaoJuan2009", "Arun2010", "Deveaud2014"),
  method = "Gibbs",
  control = list(seed = 42),
  verbose = TRUE
)

# 시각화
FindTopicsNumber_plot(result_metrics)
# Griffiths2004·Deveaud2014 → 높을수록 좋음
# CaoJuan2009·Arun2010 → 낮을수록 좋음
# 꺾이는 지점(elbow)을 최적 k로 선택

# 최적 k 설정 (탐색 결과에 따라 조정, 여기서는 k = 4 설정)
k <- 4

set.seed(42)
lda_model <- LDA(
  dtm_clean,
  k = k,
  method = "Gibbs",
  control = list(
    seed = 42,
    burnin = 1000, # 초기 샘플링 버림
    iter = 2000, # 반복 횟수
    keep = 50, # 로그 우도 기록 간격
  )
)

```

```

    thin      = 10      # 샘플 간격
  )
)

cat("토픽 수:", k, "\n")

# 로그 우도 확인 (수렴 여부)
loglik <- lda_model$loglikelihood
cat("로그 우도:", round(loglik, 2), "\n")

# β: 각 토픽에서 단어가 등장할 확률
topic_terms <- tidy(lda_model, matrix = "beta")

# 토픽별 상위 10개 단어 추출
top_terms <- topic_terms %>%
  group_by(topic) %>%
  slice_max(beta, n = 10, with_ties = FALSE) %>%
  ungroup() %>%
  arrange(topic, desc(beta))

topic_labels <- c(
  "1" = "Topic 1",
  "2" = "Topic 2",
  "3" = "Topic 3",
  "4" = "Topic 4"
)

top_terms %>%
  mutate(
    topic = factor(paste0("Topic ", topic), levels = paste0("Topic ", 1:k)),
    term = reorder_within(term, beta, topic)
  ) %>%
  ggplot(aes(x = term, y = beta, fill = topic)) +
  geom_bar(stat = "identity", show.legend = FALSE, width = 0.7) +
  geom_text(aes(label = round(beta, 4)),
    hjust = -0.1, size = 2.8, family = "notokr") +
  facet_wrap(~ topic, scales = "free_y", ncol = 2) +
  scale_x_reordered() +
  scale_fill_brewer(palette = "Set2") +
  coord_flip() +
  labs(
    title = "LDA 토픽 모델링 - 토픽별 핵심 단어 (β)",
    subtitle = paste0("RISS '빅데이터 분석' 논문 제목 | k = ", k),
    x = "단어",
    y = "β (단어 확률)"
  ) +
  theme_minimal(base_family = "notokr") +
  theme(
    plot.title = element_text(size = 13, face = "bold"),
    plot.subtitle = element_text(size = 10, color = "gray50"),
    strip.text = element_text(size = 10, face = "bold"),
    axis.text = element_text(size = 9)
  )

# γ: 각 문서가 특정 토픽에 속할 확률

```

```

doc_topics <- tidy(lda_model, matrix = "gamma")

# 문서별 주요 토픽(최댓값) 추출
doc_main_topic <- doc_topics %>%
  group_by(document) %>%
  slice_max(gamma, n = 1, with_ties = FALSE) %>%
  ungroup() %>%
  mutate(
    doc_id = as.integer(document),
    topic = factor(paste0("Topic ", topic), levels = paste0("Topic ", 1:k))
  )

cat(capture.output(as.data.frame(doc_main_topic)), sep = "\n")

# 토픽별 문서 수 시각화
doc_main_topic %>%
  count(topic) %>%
  ggplot(aes(x = topic, y = n, fill = topic)) +
  geom_bar(stat = "identity", width = 0.6, show.legend = FALSE) +
  geom_text(aes(label = paste0(n, "편")),
            vjust = -0.5, size = 4, family = "notokr") +
  scale_fill_brewer(palette = "Set2") +
  scale_y_continuous(expand = expansion(mult = c(0, 0.15))) +
  labs(
    title = "토픽별 문서 배정 수",
    subtitle = paste0("RISS '빅데이터 분석' 논문 (n = 50편) | k = ", k),
    x = "토픽",
    y = "문서 수 (편)"
  ) +
  theme_minimal(base_family = "notokr") +
  theme(
    plot.title = element_text(size = 13, face = "bold"),
    plot.subtitle = element_text(size = 10, color = "gray50"),
    axis.text = element_text(size = 10)
  )

doc_topics %>%
  mutate(topic = factor(paste0("Topic ", topic), levels = paste0("Topic ", 1:k))) %>%
  ggplot(aes(x = topic, y = gamma, fill = topic)) +
  geom_boxplot(alpha = 0.7, outlier.shape = 21, show.legend = FALSE) +
  geom_jitter(aes(color = topic), width = 0.15, alpha = 0.4,
              size = 1.5, show.legend = FALSE) +
  scale_fill_brewer(palette = "Set2") +
  scale_color_brewer(palette = "Set2") +
  labs(
    title = "문서별 토픽 소속 확률( $\gamma$ ) 분포",
    subtitle = paste0("RISS '빅데이터 분석' 논문 | k = ", k),
    x = "토픽",
    y = " $\gamma$  (토픽 소속 확률)"
  ) +
  theme_minimal(base_family = "notokr") +
  theme(
    plot.title = element_text(size = 13, face = "bold"),
    plot.subtitle = element_text(size = 10, color = "gray50"),
    axis.text = element_text(size = 10)
  )

```

사용 문서 수: 50
 사용 단어 수: 211
 DTM 행(문서) 수: 50

DTM 열(단어) 수: 174

DTM 희소성: 0.976

정제 후 문서 수: 50


```
fit models... done.
calculate metrics:
  Griffiths2004... done.
  CaoJuan2009... done.
  Arun2010... done.
  Deveaud2014... done.
```

토픽 수: 4

로그 우도: -1167.03

	document	topic	gamma	doc_id
1	1	Topic 1	0.2500000	1
2	10	Topic 1	0.2596154	10
3	11	Topic 2	0.2735849	11
4	12	Topic 1	0.2596154	12
5	13	Topic 1	0.2547170	13
6	14	Topic 3	0.2735849	14
7	15	Topic 2	0.2735849	15
8	16	Topic 4	0.2719298	16
9	17	Topic 1	0.2636364	17
10	18	Topic 4	0.2685185	18
11	19	Topic 1	0.2844828	19
12	2	Topic 2	0.2636364	2
13	20	Topic 2	0.2735849	20
14	21	Topic 3	0.2767857	21
15	22	Topic 1	0.2924528	22
16	23	Topic 2	0.2596154	23
17	24	Topic 2	0.2685185	24
18	25	Topic 1	0.2500000	25
19	26	Topic 2	0.2685185	26
20	27	Topic 3	0.3135593	27
21	28	Topic 2	0.2719298	28
22	29	Topic 1	0.2543860	29
23	3	Topic 4	0.2818182	3
24	30	Topic 4	0.2735849	30
25	31	Topic 1	0.2636364	31
26	32	Topic 4	0.2636364	32
27	33	Topic 3	0.2636364	33
28	34	Topic 4	0.2636364	34
29	35	Topic 3	0.2596154	35
30	36	Topic 1	0.2500000	36
31	37	Topic 2	0.2672414	37
32	38	Topic 4	0.2647059	38
33	39	Topic 3	0.2946429	39
34	4	Topic 1	0.2818182	4
35	40	Topic 3	0.2636364	40
36	41	Topic 1	0.2547170	41
37	42	Topic 2	0.2735849	42
38	43	Topic 3	0.2735849	43
39	44	Topic 1	0.2636364	44
40	45	Topic 2	0.2547170	45
41	46	Topic 2	0.2685185	46
42	47	Topic 2	0.2543860	47
43	48	Topic 4	0.2636364	48
44	49	Topic 2	0.2735849	49
45	5	Topic 2	0.2647059	5
46	50	Topic 1	0.2636364	50
47	6	Topic 4	0.2788462	6

48	7 Topic 2	0.2647059	7
49	8 Topic 2	0.2735849	8
50	9 Topic 1	0.2589286	9



LDA 토픽 모델링 — 토픽별 핵심 단어 (β)


RISS '빅데이터 분석' 논문 제목 | $k = 4$

토픽


Topic 1




Topic 2



Topic 3




Topic 4



β (단어 확률)

토픽별 문서 배정 수

RISS '빅데이터 분석' 논문 (n = 50편) | k = 4



문서별 토픽 소속 확률(γ) 분포

RISS '빅데이터 분석' 논문 | $k = 4$

