

# 임베디드 소프트웨어: 사인파 모델 학습 과제

Park Jonghyeon  
컴퓨터정보통신공학과  
전남대학교 공과대학  
jonghyeon@jnu.ac.kr

**Abstract**—사인파 학습 데이터와 모델 파라미터가 모델 성능에 끼치는 영향을 분석하고 그 결과를 정리하기 위해 3가지의 변형을 실험하고 그 결과를 정리했습니다.

## I. 모델 정의

실험은 두 개의 모델과 두 개의 데이터를 이용하여 총 세 개 유형으로 진행하였습니다. 두 개의 모델로 “기본형 모델”과 “깊은 모델”을 정의하였습니다. 기본형 모델은 사인파 학습 예제에 널리 사용되는 유형의, Dense 레이어가 적당한 수준으로 쌓여있는 구조입니다. 자세한 구조는 표 1을 참조하십시오.

깊은 모델은 기본형 모델보다 더 많은 은닉층을 가지고 있지만 여전히 Dense 레이어만으로 구성됩니다. Dense 레이어는 점점 넓어지다가 다시 축소되는 과정을 거칩니다. 자세한 구조는 표 2를 참조하십시오.

TABLE I: 유형 a와 b에서 사용하는 기본형 모델의 구조

Type	Activation Fn	Output Shape
Dense	ReLU	32
Dense	ReLU	64
Dense	ReLU	16
Dense	ReLU	1

TABLE II: 유형 c에서 사용하는 깊은 모델의 구조

Type	Activation Fn	Output Shape
Dense	ReLU	32
Dense	ReLU	64
Dense	ReLU	64
Dense	ReLU	128
Dense	ReLU	64
Dense	ReLU	64
Dense	ReLU	16
Dense	ReLU	1

## II. 학습

학습에 사용하는 데이터는 모두  $[0, 2\pi]$  범위에 분포됩니다. 하지만 실험군은 가운데에 데이터가 몰려 범위의 가장자리가 학습이 잘 되지 않도록 하였습니다. 실험군의  $x$  좌표 분포는  $m = 0, \sigma = 1$ 의 정규 분포를 생성한 후  $[0, 2\pi]$  구간으로 변환하였습니다. 따라서 실험군의 분포는 생성된 값의 이상치 분포에 따라 결정됩니다.

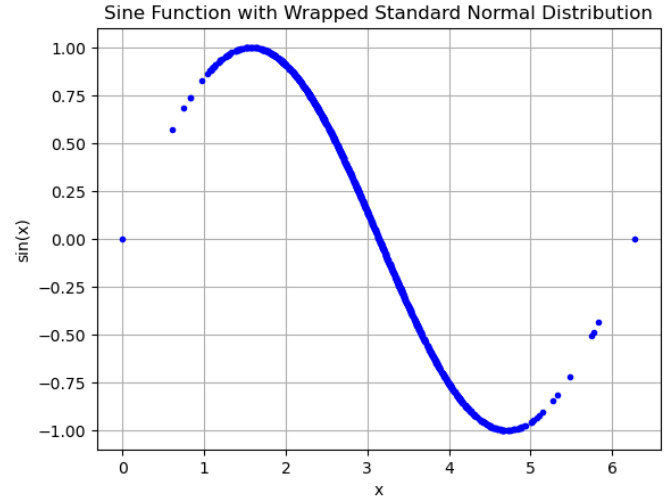


Fig. 1: 실험군: 중앙에 몰린 데이터




Fig. 2: 실험군: 중앙에 몰린 데이터(학습용 노이즈 추가)

이와 같이 구간 데이터를 엄밀하게 정의하지 않은 것은 이 실험군의 목적이 단순히 범위 가장자리의 데이터가 빈약할 때의 학습 결과를 확인하는 것이기 때문입니다. 따라서 설정한 시드값에 따라 구간 데이터가 변화할 수 있으며, 정의역이 비결정적으로 생성되는 것처럼 보일 수 있습니다.

이와 달리 대조군은  $[0, 2\pi]$  구간에 고르게 퍼져있도록 하였습니다. 최종적으로, 생성한 실험군과 대조군은  $[0, .15]$  수준의 노이즈를 덧셈하여 학습에 사용하였습니다.




Fig. 3: 대조군: 고르게 분포된 데이터




Fig. 5: 깊은 모델의 학습/검증 로스




Fig. 4: 기본형 모델의 학습/검증 로스




Fig. 6: 기본형 모델의 사인파

### III. 실험 결과

#### A. 모델의 깊이에 따른 정확도 변화

깊은 모델은 기본형 모델에 비해 학습 과정이 더 불안정했습니다. 학습 중 validation loss가 지속적으로 큰 폭으로 변동하며 튀는 현상이 관찰되었습니다. 이러한 현상으로 인해 학습이 진행되는 동안 모델이 중간중간 과적합된 것이 아닌지 우려되는 상황이 발생하였습니다.

두 모델이 예측한 사인파 그래프에서는 큰 차이를 확인할 수 없었습니다. 따라서 깊은 모델의 도입은 실질적으로 성능 개선에 기여하지 않았으며, 오히려 컴퓨팅 자원의 낭비와 과적합에 대한 우려만 남기는 결과를 가져왔습니다.

이는 설계한 깊은 모델이 사인파 추정 문제를 해결하기에는 지나치게 복잡한 구조를 가지고 있었기 때문인 것으로 보입니다. 사인파와 같이 단순한 패턴을 추정하는 데에는 기본형 모델만으로도 충분히 대응 가능한 것으로 보입니다.




Fig. 7: 깊은 모델의 사인파

## IV. 부록

### A. 각 유형 별 Loss 값

Type	$L$ Epoch.30	$L$ Epoch.50	$L$ Epoch.100
기본형 + 대조군	0.0575	0.0367	0.0302
기본형 + 실험군	0.0398	0.0358	0.0301
기본형 + 실험군(10배)	0.0259	0.0251	0.0246
깊은 모델	0.0427	0.0386	0.0333




Fig. 8: 실험군으로 학습시킨 모델의 사인파




Fig. 9: 입력 개수를 10배 증가시킨 실험군으로 학습시킨 모델의 사인파

### B. 데이터의 분포에 따른 정확도 변화

가운데가 조밀한 실험군은 데이터 분포가 범위의 가장자리에 거의 존재하지 않아 끝부분 학습이 사실상 불가능하게 되었습니다. 그 결과로 수행한 테스트에서, 모델은 사인파 보다는 시그모이드 함수를  $y$ 축 대칭한 형태의 개형에 가깝게 그래프를 그렸습니다.

추가 연구로서 이를 보완하기 위해 데이터 개수를 수 배 늘려서 생성하기도 하였으나, 표준편차를 변경하지 않았기 때문에 단순히 데이터 수를 증가시키는 것으로는 학습 데이터의 분포에 유의미한 변화를 가져오지 못했습니다.

그럼에도 불구하고 그래프 자체는 훨씬 개선되어 사인파 곡선을 그려낼 수 있었습니다. 이것은 범위 가장자리의 데이터가 상대적으로 빈약함에도 불구하고, 원본 실험군과 달리 가장자리에서 사인파를 묘사할 수 있는 데이터가 포함되었기 때문으로 추정하고 있습니다.