


#제1장


3/10.

#제1장 개념.


- 입력 → 출력.
- 입력 → 목표치.



- 특징화.



⇒ d-차원...



· 데이터베이스 정보...

⇒ DB ↑ ⇒ 정확도 ↑ ... ↑

#전환 예시.

$f_\theta(x_i)$ : 예측값의 출력.  
 $y_i$ : 목표치.

$$\text{Loss}^{\text{MSE}} = J(\theta) = \frac{1}{n} \cdot \sum_{i=1}^n (f_\theta(x_i) - y_i)^2$$

예


$$\theta_1 = (w_1, b_1)^T \rightarrow \theta_2 \rightarrow \theta_3 \dots \rightarrow \hat{\theta}$$

argmin  $J(\theta) = \hat{\theta}$   
 $\theta$  ↓  
 최적의  $\theta$ ?

#계략습.

#비선형 모델. 자주 나타나는 문제들.

3/10.




→ 비선형 모델 필요.



1차

2차 ...


N차



과소적합



과대적합.



↓  
적절한 모델 선택

· 바이어스.

~~분산~~  
~~바이어스~~

↑

↓



↑



↓





# 계층


# 그림

3/10.

in: 모델 집합  $\Rightarrow$  학습 집합, [검증 집합], 테스트 집합.

out: 최적 모델, 성능.


훈련  $\rightarrow$  학습  $\rightarrow$  평가  $\rightarrow$  테스트 결과...



가장 좋은 성능  
4 모델

# 데이터셋

· 난수로 임의 샘플링.



임의 비율로 나누어 각 집합에 사용.

in: 모델 집합, 샘플링 비율  $P$ , 수행 횟수  $T$ .

$\rightarrow$   $P$  개 샘플 훈련 집합에서 추출  
\* \*'

\*'에서 모델 학습  $\rightarrow$  \* - \*'로 loss 평가.

# Grid 탐색

grid  $\uparrow \Rightarrow$  성능  $\uparrow$ .

· 인위적으로 Grid를 변경해서 ... 최적의 값, 하이퍼 파라미터 스케일링, 도메인 섀깅 등 ...

# 가중치 규제

$y = \cos n(x^{2m} - 2m \cos x) + \dots$   $\rightarrow$  가중치  $\uparrow$ .

$J(\theta) = \frac{1}{n} \sum_{i=1}^n (\phi_0(x_i) - y_i)^2 + \lambda \|\theta\|_2^2 \sim$  가중치 규제함.

# 체계 학습

# 체계 학습의 유형

· 기초 학습

\*  $X$ 와  $Y$  모두 주어짐  $\Rightarrow$  외기, 분류 문제

· 비지그 학습

\* 주어지나  $Y$  주어지지 않음,  $\rightarrow$  근접화, 보조정 등

· 강화 학습

특정가 주어짐, 보상 제공

· 증기르 학습

\* 주어짐, 일부분만  $Y$  주어짐

· 표정론적 학습, 스토캐스틱 학습

표정론적  $\rightarrow$  항상 정확히 처리 } ... 스토캐스틱에 따른 불확실성이 결정론적으로  
스토캐스틱  $\rightarrow$  X









#제1과제

#중력이 여러개인 프렉트론.

03/17.

· 중력 벡터  $O = (0, 0, \dots, 0)^T$ 로 표기

· 중력에 프렉트론 중력  $W_i = (w_1, w_2, \dots, w_c)^T$ 로 표기

$$\Rightarrow O = C \begin{pmatrix} w_1 \cdot x \\ w_2 \cdot x \\ \vdots \\ w_c \cdot x \end{pmatrix}$$

\* 분류:  $\hat{O} = C(W \cdot X)$

회귀:  $\hat{O} = C(\hat{W} \cdot X)$

#선형과 벡터공간.

$C = \alpha_1 a + \alpha_2 b$ .  $\rightarrow$  벡터  $a$ 와  $b$ 의 선형결합.

\* 두 벡터가 독립이다.  $\rightarrow$  · 상수배가 다르다. · 평행하지 않다.

$\left\{ \begin{array}{l} \cdot \end{array} \right.$

· 외적 결과가 0이다 · 중력이 다르다.

· sin 결과가 0이다

두 벡터 사이의 각을 나타낸다.

#행렬.

· 행렬식 det  $\rightarrow \det \begin{pmatrix} A & B & C \\ D & E & F \\ G & H & I \end{pmatrix} = AEI + BFG + CDH - (CEG + BDI + AFH)$

· 기하적 의미 2차원 상 넓이, 3차원 상 부피.


계산함. #2와 #3과 2차 벡터의 기하학적 해.

$$x' = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1/\sqrt{5} \\ 1/\sqrt{5} \end{pmatrix} = \begin{pmatrix} 3/\sqrt{5} \\ 2/\sqrt{5} \end{pmatrix}$$

A                  x<sub>1</sub>

\* 회전 행렬

$$R(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$



\* 스케일 행렬.

$$S = \begin{bmatrix} c & 0 \\ 0 & c \end{bmatrix} \rightarrow \text{대각선에 상수... 크기 변환}$$

$$\Rightarrow A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \rightarrow \text{스케일을 줌.}$$

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

x<sub>2</sub>                  x<sub>1</sub>

$$\{A \text{의 고유값}\} \text{이 같은 방향의} \\ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$x_1 = \begin{pmatrix} 1/\sqrt{5} \\ 1/\sqrt{5} \end{pmatrix}, x_2 = \begin{pmatrix} 1/\sqrt{5} \\ -1/\sqrt{5} \end{pmatrix} \text{는} \\ \text{스케일이 변하지 않는 방향을 유지.}$$



#계량

#확률과 통계. → 계량이 치환 가치는 불확실한 상황에서 발생.  
→ 불확실성이 다른 통계. 확률 처리.

확률 변수 random Variable.

예시 —  $Y: 1/16, Z: 2/16.$

↓  
실제로 실행할 때 다음.

예시 — 확률 변수: 4개 (꽃말림 크기, 꽃말림 크기, 꽃말림 크기, 꽃말림 크기)  
→ 4개의.

#공공과 공공.

공공:  $P(y, x) = P(x|y) P(y).$

공공:  $P(x) = \sum_y P(y, x) = \sum_y P(x|y) P(y).$

→ 확률이 변할 확률.

$P(\text{하양}) = P(\text{하양}(x)) P(x) + P(\text{하양}(y)) P(y) + P(\text{하양}(z)) P(z)$

"하양 공이 나왔다는 사실 알고, 어느 방에서 나왔는지 모르겠을 때,  
어느 방에서 나왔는지 추정하다"

$\hat{y} = \underset{y}{\operatorname{argmax}} P(y|x).$   
↓      ↓  
방      하양공.

#비디즈 정리.

$\hat{y} = \underset{y}{\operatorname{argmax}} P(y|x = \text{하양})$   
↓      ↓      ↓  
공공      하양      사건확률.  
 $= \underset{y}{\operatorname{argmax}} \frac{P(x = \text{하양} | y) P(y)}{P(x = \text{하양})}$   
사후확률.

$P(\text{①} | \text{하양}) = 2, 7$   
↓  
 $P(\text{②} | \text{하양}) = 8.$   
↓  
 $P(\text{③} | \text{하양}) = 7.$   
↓  
일대

# 소개

# 평균과 분산

\* Gaussian의 1차 함수로서 평균과 분산

$$\text{평균 } \mu = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{분산 } \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

\* 평균 벡터와 분산 행렬

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$


$$\Sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$$

$$= \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1d} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2d} \\ \vdots & & \ddots & \\ \sigma_{d1} & \sigma_{d2} & \dots & \sigma_{dd} \end{pmatrix} = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1d} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2d} \\ \vdots & & \ddots & \\ \sigma_{d1} & \sigma_{d2} & \dots & \sigma_{dd} \end{pmatrix}$$

\* 1차 분포

$$N(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right)$$

i.e. " "  $\rightarrow$  표준 정규분포





# 계측.

# 메시지가 가진 정보 ... 양화하기.

"그게 사실이 들어 왔다." } - 0 확률이 높을수록 정보량.  
"대단한일이 들어 왔다."

# 자기 정보 self information.

한  $e_i$ 의 정보량.

\* 엔트로피가 높다 = 정보량이 많다.

\* 엔트로피.  $(\sum_{i=1}^n)$

$$H(x) = - \sum_{i=1}^n P(e_i) \log_2 P(e_i).$$

$$\text{or } - \sum_{i=1}^n P(e_i) \log_e P(e_i).$$

#交叉 엔트로피. - 두 확률분포 P, Q 사이의 엔트로피.

$$H(P, Q) = - \sum P(x) \log_2 Q(x).$$

$$= - \sum_{i=1}^n P(e_i) \log_2 Q(e_i).$$

$$= - \sum_x P(x) \log_2 P(x) + \sum_x P(x) \log_2 P(x).$$

$$- \sum_x P(x) \log_2 Q(x).$$

$$= H(P) + \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}.$$

~~~~~ KL divergence.

# 기계학습

# 최적화기법

\* 최적화기법

# 매개변수 공간의 함수

$J(\theta)$  —> objective function —>  $\theta$   
 목적함수                      최적화

{ 변수 생성  $\Rightarrow$  최적화  $\theta$ .  
 $J(\theta)$ 가 작아진 방향  $d\theta$ .  
 $\theta = \theta + d\theta$ .  
 반복.  
 $\theta = \theta$ .

$\theta = \{w, b\}$

$J(\theta) = \frac{1}{n} \sum_i (f_\theta(x_i) - y_i)^2$  —> 도함수  $J'(\theta) = 0$ 을 풀어 구함.

최적화기법

—> 최적화기법 방법론

$\theta = \{w\}$

$J(w) = \sum_{x \in \mathcal{X}} -y_k (w^T \cdot x_k)$   
 Loss

—> 스코어와 경사 방법

파라미터

—> 최적화 방법론


$\theta = \{w_1, w_2, \dots, w_k\}$

$c = \frac{1}{2} \|y - o\|_2^2$

—> 스코어와 경사 방법

입력

—> 최적화 방법론



$$f_{x+i} = f_x - f'_x \cdot \rho \text{ (학습률)}$$

\* ~~이제~~ 선형 최적화와 유사한 선형 최적화 알고리즘



# 계측법. # 편미분.  $\rightarrow$  방향이 다른 벡터  $\rightarrow$  그래디언트.

$$\cdot \nabla f, \frac{\partial f}{\partial x}, \left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2} \right) \dots$$

$\Rightarrow$  편미분은 같은 그래디언트를 이용해 최적화에 접근.

(# 연쇄법칙.)  $\downarrow$

$$\left. \begin{aligned} f(x) &= g(h(x)) \\ f'(x) &= g'(h(x)) h'(x). \end{aligned} \right\}$$

$\downarrow$   
각각의 미분법

$\propto$  Batch Gradient Descent.

# 손실/손실 함수 하강 Stochastic Gradient Descent.

한 샘플의 그래디언트를 계산 후 하강



# 배치 함수 하강 Batch Gradient Descent.

샘플의 그래디언트를 평균한 후 한 번에 하강.


... 계측법과 수학

이제 잊음.

# 신경망

· 깊이 깊어짐  $\Rightarrow$  비선형  $\uparrow$   
 2층 미연  $\uparrow$   $\rightarrow$  제약 어려움.  
 피드백  $\downarrow$

\* 비선형 XOR 문제



# 목적 함수 설계.

$J(0)$  또는  $J(w)$   $\rightarrow$  조건.  
 $= \sum_{x \in X} \frac{1}{2} (w^T x - y)^2$  일때  
 $\downarrow$   $\downarrow$   $\downarrow$   
 평균 제곱 오차.  $\downarrow$   $\downarrow$   $\downarrow$   
 조건.  
 1.  $J \geq 0$   
 2. 최적이면  $J(w) = 0$ .  
 3. 많은 샘플  $\uparrow$  빠를수록  $J(w) \rightarrow 0$ .

$\left. \begin{matrix} 1 & -1 & \rightarrow \\ 1 & 1 & \rightarrow \\ -1 & 1 & \rightarrow \end{matrix} \right\}$   $\downarrow$   $\downarrow$   $\downarrow$   
 이는 바이트 들은 샘플의 집합.



계산.

#그라디언트.

$$\frac{\partial J(w)}{\partial w_i} = \sum_k \frac{\partial (-y_k (w_0 x_{k0} + w_1 x_{k1} + \dots + w_d x_{kd}))}{\partial w_i}$$

$$= \sum_{k \in T} -y_k x_{ki} \quad (i=0, 1, \dots, d).$$

↓

$$w_i = w_i + \rho \sum_{k \in T} y_k x_{ki} \quad (i=0, 1, \dots, d).$$

#학습.

훈련집합  $X$ 와  $Y$ 에 대해, 샘플을 모두 보지 ( $T=\emptyset$ )인 경우 학습 종료.

이것이 'Perceptron'.


\* 퍼셉트론의 한계  $\rightarrow$  선형 분류.

$\Rightarrow$  다층 퍼셉트론  $\left\{ \begin{array}{l} \cdot \text{은닉층 사용} \dots \text{특정 공간을 분류하기 쉬운 공간으로 변환.} \\ \cdot \text{12모드 활성화함수.} \\ \cdot \text{가중 역전파 알고리즘.} \end{array} \right.$

즉, 이

'Parallel Distributed Processing'.


"공간이 하나의 점으로 매핑됨."



특정  $x$ 를 특정 공간으로 변환.

가계좌

# 특징공간 변환.




이상은 3개 사용

|       | ① < 0 | ① > 0 |
|-------|-------|-------|
| ② < 0 | a     | b     |
| ② > 0 | c     | d     |
| ③ > 0 |       |       |


3개의 공간으로 분할.

|       | ① < 0 | ① > 0 |
|-------|-------|-------|
| ③ < 0 | e     | f     |
| ③ > 0 | g     | h     |
| ⑤ < 0 |       |       |

3개의 "유형"을 점으로 생각하여 새 공간에 매핑.




# 공간분할.



1D space의 간단한 공간분할.



3개의 sig.의 부호를 공간분할





3/19.

차이값


#활성화

$$\begin{aligned} 0 \leq f \leq 1 &\rightarrow (b-a)f &\rightarrow (b-a)f + a. \\ &\Rightarrow 0 \leq (b-a)f \leq b-a. &\Rightarrow a \leq (b-a)f + a \leq b. \end{aligned}$$

3/24.

#23

· 입력층 - 은닉층 - 출력층.



let.

$U'$  입력층 - 은닉층 연결.

$U''$  은닉층 - 출력층 연결.

$$U'' = \begin{pmatrix} u''_{10} & u''_{11} & \dots & u''_{1d} \\ u''_{20} & & & \\ \vdots & & & \\ u''_{p0} & & & u''_{pd} \end{pmatrix}$$

\*  $j$  번째 은닉 노드:  $z_j = \tau(z_{sumj})$ ,  $j = 1, 2, \dots, p$ .

$$z_{sumj} = \underline{u}_j' \underline{x}$$

$$\underline{u}_j' = (u'_{j0}, u'_{j1}, \dots, u'_{jd}),$$

$$\underline{x} = (1, x_1, x_2, \dots, x_d)^T.$$

# 9주 연산과 알고리즘의 설계.

# 미니배치 알고리즘의 장단점.  $\rightarrow$  한 번에  $k$  개의 샘플 처리.

$\Rightarrow$  GPU 이용 병렬처리

3/24

기계학습.

#사이킷런.

Model Selection  $\rightarrow$  검사 방법 / 과적합.  $\rightarrow$  발생함  $\rightarrow$  방지책.  $\left\{ \begin{array}{l} \text{regulation.} \\ \text{regularization} \end{array} \right.$

\*교차 검증 : 과적합 문제 해결  $\left\{ \begin{array}{l} \text{K-fold 검증.} \\ \text{Stratified K-fold.} \end{array} \right.$

\*Grid Search CV

데이터 전처리 : 머신러닝 알고리즘  $\rightarrow$  <sup>\*\*</sup> NaN/Null 등 처리 x?  $\left\{ \begin{array}{l} \text{문자열 값 x.} \\ \text{처리} \end{array} \right.$

피처 스케일링 - 정규화.

. Standard Scaler : 차이를 따르도록.

. MinMax Scaler : 0 ~ 1 범위

label encoding.  
one-hot encoding



개념.

# Ensemble 방법.

주의.

- 이득 스코어 이상 분류기 선택 여파.
- 복수의 약한 분류기 사용.
- { 미분형 (이미지, 영상, 음성 등) → 딥러닝  
정형 → 앙상블 }

# Voting.

각 결과 → 투표.  
여러 결과들.

# Bagging.

같은 데이터셋.  
다른 디버전 생성.  
(중복 허용).  
↓ Voting.

# Boosting

여러 결과들 순차 학습  
이름 들린 데이터  
→ next 단계로  
맞출 수 있게 조정  
i.e. GBM, XGBoost, ...

# Softing

여러 모델 예측값 → 확률 모델화.  
→ 다른 모델을 재 학습.  
(여러 모델).


\* Hard Voting vs Soft Voting  
↳ 다수결. ↳ 확률 평균

# Voting Classifier.

\* Logistic Regression + KNN  
⇒ Voting Classifier (Soft).

가계략함.

# 다중 클래스 분류 문제.



\* Multi Neural.

$$D \begin{pmatrix} \theta_0^1 x_0 + \theta_1^1 x_1 + \theta_2^1 x_2 \\ \theta_0^2 x_0 + \theta_1^2 x_1 + \theta_2^2 x_2 \\ \theta_0^3 x_0 + \theta_1^3 x_1 + \theta_2^3 x_2 \end{pmatrix} = \begin{bmatrix} 2. \\ 1. \\ .1 \end{bmatrix} \rightarrow F \begin{bmatrix} 2. \\ 1. \\ .1 \end{bmatrix} = \begin{bmatrix} .66 \\ .24 \\ .10 \end{bmatrix}$$

\* Softmax.

$$F \begin{bmatrix} 2. \\ 1. \\ .1 \end{bmatrix} \rightarrow S(y^{(2)}) = \frac{e^{y^{(2)}}}{\sum_2 e^{y^{(2)}}} \rightarrow \begin{bmatrix} .66 \\ .24 \\ .10 \end{bmatrix}$$


+1 Confusion Mat.

\* Cross Entropy.

# K-클래스 분류.


- 어떤 클래스 → K개의 차분 차분 분류.
- 특징 공간 내의 모든 클래스 분류.
- 분류 성능 ↑.
- 다중-클래스 / 다중-클래스 분류.





$$C = \underbrace{-y}_{\text{정답}} \log(H(x)) - \underbrace{(1-y)}_{\text{정답}} \log(1 - H(x))$$

# Support Vector Machine.



$h_1$ :  $C$  나쁜 분류.

다른 나쁜  $C$  값은  $h_1$  오답률  
 $\Rightarrow$   $h_1$  오답률  $\uparrow$  하는 것.