

온도, 녹조, 더러움...

*팔당댐 수질관리 데이터 분석
~회귀 문제의 분류 문제화와 함께~*

2025/04/27

박종현

공과대학 컴퓨터정보통신공학과

AI Hub

AI 데이터찾기

AI 허브소개

참여하기

커뮤니티

AI 개발지원

고객지원

로그인

회원가입

데이터 찾기

AI 데이터찾기 > 데이터 찾기



#취수원 #상수원 #지하수 #수위 #수량 #수질 #녹조 #환경

상수원-취수원 통합 수질 및 녹조 데이터

분야 재난안전환경 유형 텍스트

구축년도 : 2022 갱신년월 : 2024-06 조회수 : 7,257 다운로드 : 448 용량 : 460.55 MB

다운로드

↓ 샘플 데이터 ?

관심데이터 등록

39

소개

파일 목록 (API 다운로드)

※ 내국인만 데이터 신청이 가능합니다.

문의하기

목록

데이터 개요

메타데이터 구조표

데이터 통계

온도와 녹조의 상관관계

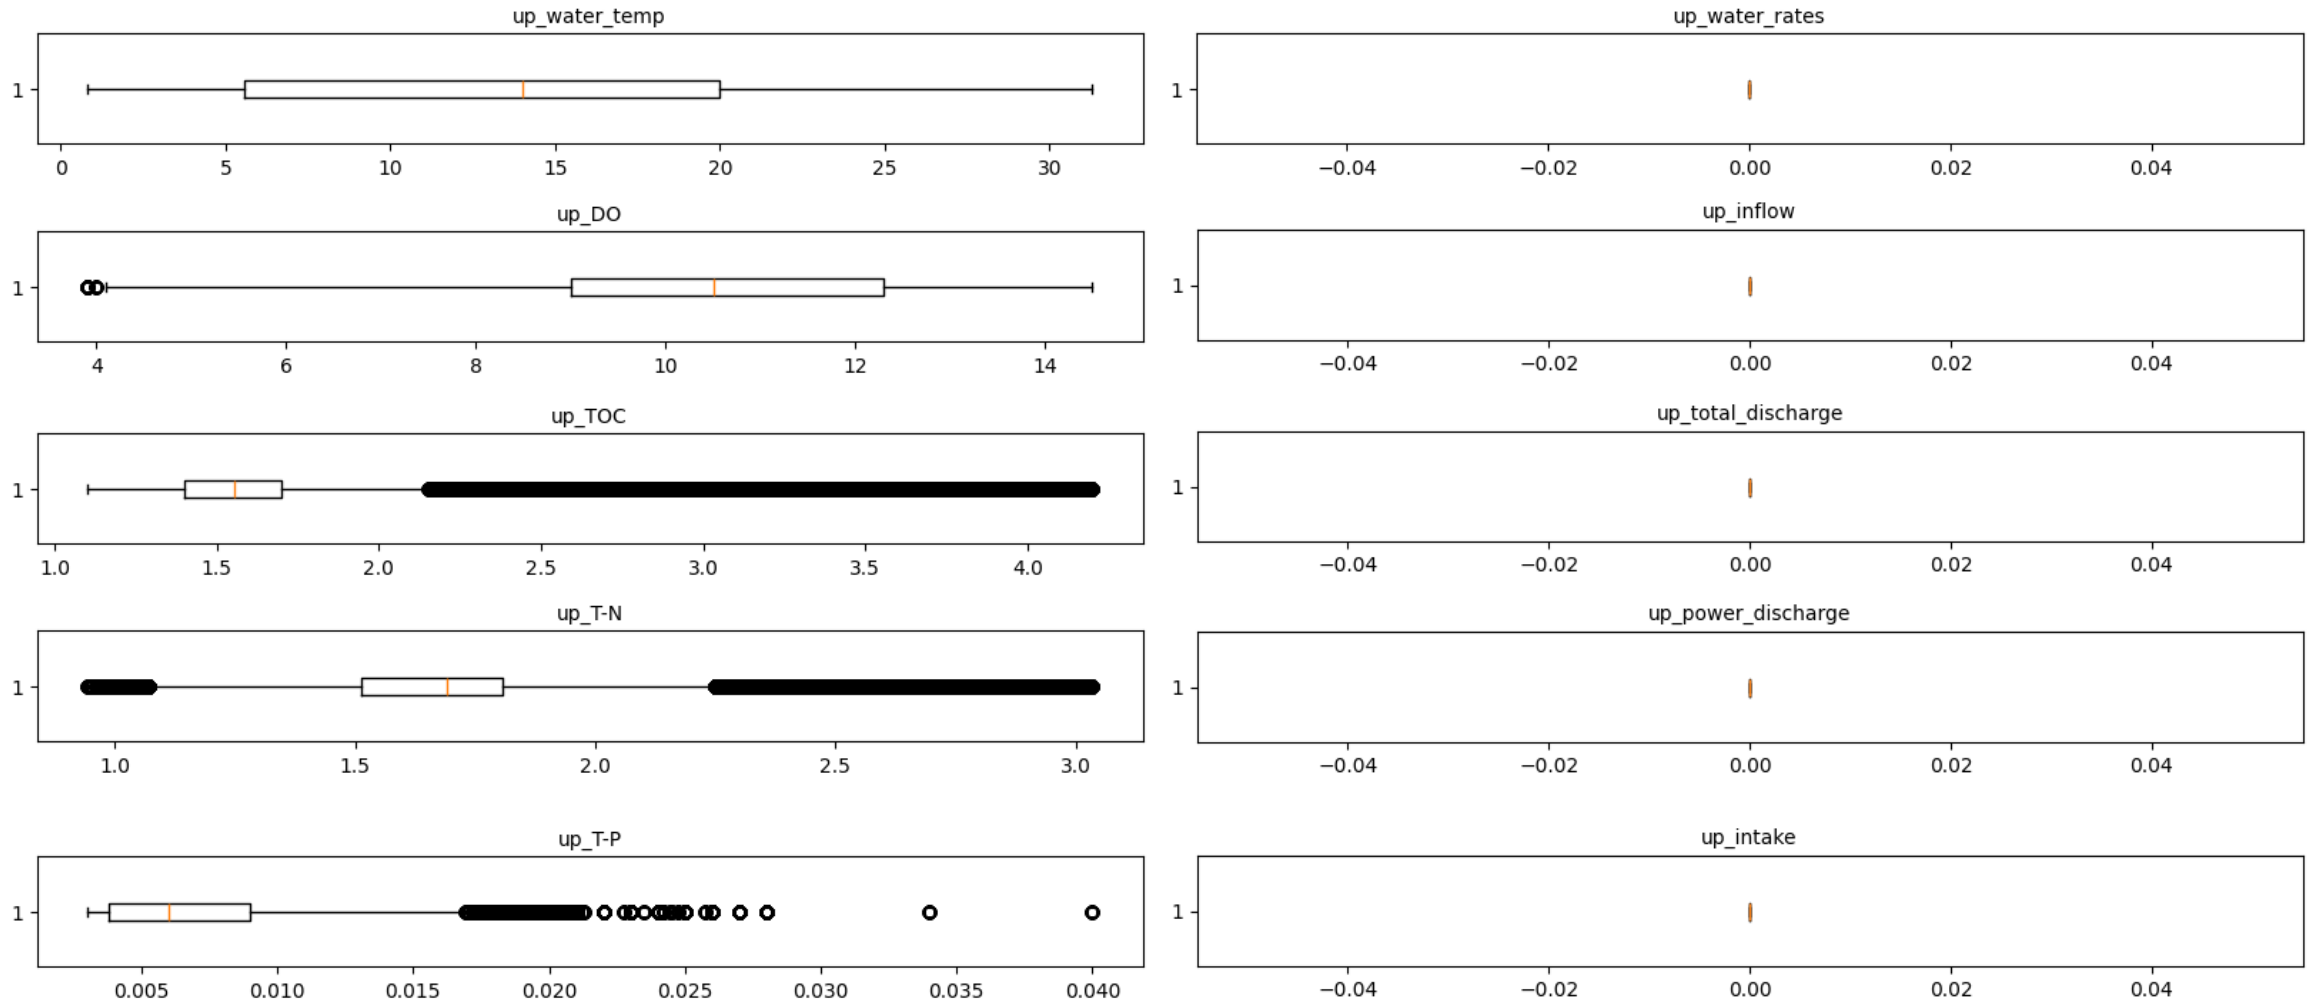
녹조 데이터는 사진으로 제공되고 있었음

측정지점ID	measure_id	측정지점ID	기온	temp	기상정보 (3개)	오염원_탁도	p_turbidity	오염원 (7개)
측정지점ID	measure_date	측정일시	강우량	precipitation		오염원_전기전도도	p_EC	
탁도	turbidity	수질측정항목(19개)	풍속	wind_velocity		오염원_수온	p_DO	
전기전도도	EC		상류_탁도	up_turbidity	상류수질측정 (상수원) (8개)	오염원_용존산소	p_water_temp	
산성도	pH		상류_전기전도도	up_EC		오염원_총유기탄소	p_TOC	
수온	water_temp		상류_산성도	up_pH		오염원_총질소	p_T-N	
용존산소	DO		상류_수온	up_water_temp		오염원_총인	p_T-P	
총유기탄소	TOC		상류_용존산소	up_DO				
조류	algae		상류_총유기탄소	up_TOC				
알카리도	alkalinity		상류_총질소	up_T-N				
남조류	blue_algae		상류_총인	up_T-P				
잔존염소	residual_Cl		상류_저수위	up_water_level	상류수리수문 (8개)			
청녹조류	blue-green_algae		상류_저수량	up_water_volume				
규조류	diatomeae		상류_저수율	up_water_rates				
은편모조류	cryptophyceae		상류_유입량	up_inflow				
2-MIB	2-MIB		상류_총방류량	up_total_discharge				
지오스민	Geosmin		상류_발전방류량	up_power_discharge				
시네드라	synedra		상류_취수량	up_intake				
총질소량	T-N		상류_수문방류량	up_gate_discharge				
총인량	T-P							
망간	Mn							


데이터는 온전한가

#	Column	Count	Non-Null	Dtype
0	measure_id	1312920	non-null	object
1	measure_date	1312920	non-null	object
2	turbidity	1312920	non-null	float64
3	EC	1312920	non-null	float64
4	pH	1312920	non-null	float64
5	water_temp	0	non-null	float64
6	DO	0	non-null	float64
7	TOC	0	non-null	float64
8	algae	0	non-null	float64
9	alkalinity	0	non-null	float64
10	blue_algae	0	non-null	float64
11	residual_Cl	0	non-null	float64
12	blue_green_algae	0	non-null	float64

ax.boxplot(df[each])



언급할만한 데이터



	A	B	C	D	E	F	G	H	I	J	K	L	
1	measure	measure	turbidity	EC	pH	water_t	DO	TOC	algae	alkalinit	blue_alc	residual	b
304427	C001	#####	868.375	155.4583	7.9844								
304428	C001	#####	867.75	155.125	8.2066								
304429	C001	#####	868.375	154.7917	8.1384								
304430	C001	#####	867.75	154.4583	7.994								
304431	C001	#####	868	154.125	7.0796								
304432	C001	#####	868	153.7917	7.578067								
304433	C001	#####	868.625	153.4583	8.076533								
304434	C001	#####	868.625	153.125	8.575								
304435	C001	#####	868	152.7917	8.645								
304436	C001	#####	867.75	152.4583	8.6502								
304437	C001	#####	868.625	152.125	8.6284								
304438	C001	#####	868	151.7917	8.6336								
304439	C001	#####	867.75	151.4583	8.624								
304440	C001	#####	868.625	151.125	8.624								

목표 재설정

온도와 녹조의
상관관계



온도와 탁도의
상관관계

회귀 문제의 분류 문제화

```
nvim exec.py
39% 15 GB 80%

30 def categorize_turbidity(value):
29     if value < 0.5:
28         return 0
27     elif value < 1.0:
26         return 1
25     elif value < 5.0:
24         return 2
23     elif value < 25:
22         return 3
21     elif value < 150:
20         return 4
19     else:
18         return 5
17
16 def categorized_turbidity_nameing(value):
15     if value == 0:
14         return "Drinkable"
13     elif value == 1:
12         return "Drinkable (Previous)"
11     elif value == 2:
10         return "Washington Water Body Standard"
9     elif value == 3:
8         return "Vermont Water Body Standard"
7     elif value == 4:
6         return "Least Louisiana Water Body Standard"
5     else:
4         return "Dirtry"
3
2 generated = pd.DataFrame(df[["temp", "turbidity"]])
1 generated["turbidity_cls"] = df["turbidity"].apply(categorize_turbidity)
31
```

y

X

1	measure date	1312920	non-null	ob
2	turbidity	1312920	non-null	fl
3	EC	1312920	non-null	fl
4	pH	1312920	non-null	fl
5	temp	1312920	non-null	fl
6	precipitation	1312920	non-null	fl

노이즈 생성

```
nvim exec.py 15 GB 80%

from random import randint, choice

def drop_random_cell_data(df: pd.DataFrame, n: int = 1000):
    ln_row = len(df)
    for _ in range(n):
        row = randint(0, ln_row - 1)
        col = choice(df.columns.values)
        df.loc[row, col] = np.nan

def fill_na(df: pd.DataFrame):
    df.fillna({
        "temp": df["temp"].mean(),
        "turbidity_cls": df["turbidity_cls"].mean(),
    }, inplace=True)

def apply_noise(df: pd.DataFrame, n: int = 1000):
    drop_random_cell_data(df, n)
    fill_na(df)
```

```
generated.drop(columns=["turbidity"], inplace=True)
drop_random_cell_data(generated, 3000)

[13] ✓ 0.4s

generated.info()

[14] ✓ 0.0s

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 1312920 entries, 0 to 1312919
Data columns (total 2 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   temp            1311396 non-null float64
1   turbidity_cls   1311448 non-null float64
dtypes: float64(2)

fill_na(generated)
generated["turbidity_cls"] = generated["turbidity_cls"].app

[16] ✓ 0.7s

generated.info()

[17] ✓ 0.0s

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 1312920 entries, 0 to 1312919
Data columns (total 2 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   temp            1312920 non-null float64
1   turbidity_cls   1312920 non-null int64
dtypes: float64(1), int64(1)
memory usage: 20.0 MB
```

분류기 피팅 및 정확도 평가

```
dt_clf.fit(X_train, y_train)
dt_pred = dt_clf.predict(X_test)
print("DecisionTreeClassifier Accuracy: %.4f" % accuracy_score(y_test, dt_pred))
```

[20] ✓ 1.4s

Python

... DecisionTreeClassifier Accuracy: 0.9930

```
rf_clf.fit(X_train , y_train)
rf_pred = rf_clf.predict(X_test)
print("RandomForestClassifier Accuracy: %.4f" % accuracy_score(y_test, rf_pred))
```

[21] ✓ 2m 33.5s

Python

... RandomForestClassifier Accuracy: 0.9930

```
lr_clf.fit(X_train , y_train)
lr_pred = lr_clf.predict(X_test)
print("LogisticRegression Accuracy: %.4f" % accuracy_score(y_test, lr_pred))
```

[22] ✓ 4.3s

Python

... LogisticRegression Accuracy: 0.9930

분류기 피팅 및 정확도 평가

```
from sklearn.model_selection import KFold

def exec_kfold(clf, folds=5):
    kfold = KFold(n_splits=folds)
    scores = []

    for i, (train_idx, test_idx) in enumerate(kfold.split(X)):
        X_train, X_test = X.values[train_idx], X.values[test_idx]
        y_train, y_test = y.values[train_idx], y.values[test_idx]
        clf.fit(X_train, y_train)
        pred = clf.predict(X_test)
        accur = accuracy_score(y_test, pred)
        scores.append(accur)
        print(f"Iteration #{i + 1}, Accuracy: {accur}")

    return scores
```

```
scores = exec_kfold(dt_clf, folds=5)
print("Mean Accuracy: %.4f" % np.mean(scores))
```

✓ 4.7s

```
Iteration #1, Accuracy: 0.9986785181122994
Iteration #2, Accuracy: 0.9673932912896445
Iteration #3, Accuracy: 0.9996762940620906
Iteration #4, Accuracy: 0.9998438594887731
Iteration #5, Accuracy: 0.9993678213447887
Mean Accuracy: 0.9930
```

```
from sklearn.model_selection import cross_val_score
scores = cross_val_score(dt_clf, X, y, cv=5)
```

```
for i, accur in enumerate(scores):
    print(f"Iteration #{i + 1}, Accuracy: {accur}")
print("Mean Accuracy: %.4f" % np.mean(scores))
```

[24] ✓ 4.6s

```
... Iteration #1, Accuracy: 0.9929927185205496
Iteration #2, Accuracy: 0.9929927185205496
Iteration #3, Accuracy: 0.9929927185205496
Iteration #4, Accuracy: 0.9929927185205496
Iteration #5, Accuracy: 0.9929889102153977
Mean Accuracy: 0.9930
```

Python

실험 반성

- NaN값을 더 많이 생성하고 Mean 값으로 채운 행동
- 정확도를 낮추고 싶었으면 정답 레이블에는 수행하면 안되었음
- 틀린 데이터가 정답이 된 데이터를 학습하였을 뿐임

